Теория информации

Михаил Михайлов

2026

Оглавление

1 Введение в теорию информации **3**

1.1 Введение в теорию информации . . . 4

1.1.1 Теория информации: предмет, мотивация и исторический контекст . . . 4

1.1.2 Модель коммуникации Шеннона–Уивера . . . 5

1.1.3 Собственная информация . . . 7

1.2 Энтропия . . . 9

1.2.1 Понятие об опыте. Энтропия Шеннона . . . 9

1.2.2 Неравенство Гиббса. Оценки энтропии . . . 9

Приложение. О различных смыслах энтропии . . . 10

Приложение. Неравенство Йенсена . . . 12

1.3 Условная и совместная энтропия . . . 13

1.3.1 Совместная и условная собственная информация . . . 13

1.3.2 Условная энтропия. . . . 14

1.3.3 Совместная энтропия . . . 16

1.3.4 Вариации на тему правила цепочки . . . 18

1.4 Взаимная информация . . . 22

1.4.1 Взаимная информация . . . 22

1.4.2 Условная взаимная информация . . . 23

1.4.3 Информация взаимодействия . . . 25

1.5 Энтропия случайных величин . . . 27

1.5.1 Энтропия дискретных случайных величин . . . 27

1.5.2 Дифференциальная энтропия . . . 28

1.5.3 Условная и совместная дифференциальная энтропия . . . 30

1.6 Кросс-энтропия. Дивергенция Кульбака-Лейблера . . . 32

1.6.1 Кросс-энтропия . . . 32

1.6.2 Дивергенция Кульбака-Лейблера . . . 32

1.6.3 Взаимная информация между случайными величинами . . . 33

2 Некоторые приложения **34**

2.1 Элементарные приложения . . . 35

2.1.1 Неравенство обработки данных и неравенство Фано . . . 35

2.1.2 Отбор признаков на основе взаимной информации . . . 36

2.1.3 Принцип максимума энтропии и логистическая регрессия . . . 39

ГЛАВА 1

Введение в теорию информации

Меня больше всего беспокоило, как это назвать. Я думал назвать это «информацией», но это слово использовалось слишком часто, поэтому я решил назвать это «неопределённостью». Когда я обсуждал это с Джоном фон Нейманом, у него возникла идея получше. Фон Нейман сказал мне: «Вам следует называть это энтропией по двум причинам. Во-первых, ваша функция неопределенности использовалась в статистической механике под этим именем, поэтому у неё уже есть имя. Во-вторых, что более важно, никто на самом деле не знает, что такое энтропия, поэтому в дебатах у вас всегда будет преимущество»

Клод Шеннон, «отец» теории информации.

Оглавление

1.1 Введение в теорию информации . . . 4
1.1.1 Теория информации: предмет, мотивация и исторический контекст . . . 4
1.1.2 Модель коммуникации Шеннона–Уивера . . . 5
1.1.3 Собственная информация . . . 7
1.2 Энтропия . . . 9
1.2.1 Понятие об опыте. Энтропия Шеннона . . . 9
1.2.2 Неравенство Гиббса. Оценки энтропии . . . 9
Приложение. О различных смыслах энтропии . . . 10
Приложение. Неравенство Йенсена . . . 12
1.3 Условная и совместная энтропия . . . 13
1.3.1 Совместная и условная собственная информация . . . 13
1.3.2 Условная энтропия. . . . 14
1.3.3 Совместная энтропия . . . 16
1.3.4 Вариации на тему правила цепочки . . . 18
1.4 Взаимная информация . . . 22
1.4.1 Взаимная информация . . . 22
1.4.2 Условная взаимная информация . . . 23
1.4.3 Информация взаимодействия . . . 25
1.5 Энтропия случайных величин . . . 27
1.5.1 Энтропия дискретных случайных величин . . . 27
1.5.2 Дифференциальная энтропия . . . 28
1.5.3 Условная и совместная дифференциальная энтропия . . . 30
1.6 Кросс-энтропия. Дивергенция Кульбака-Лейблера . . . 32
1.6.1 Кросс-энтропия . . . 32
1.6.2 Дивергенция Кульбака-Лейблера . . . 32
1.6.3 Взаимная информация между случайными величинами . . . 33

1.1. Введение в теорию информации

Оглавление

1.1.1 Теория информации: предмет, мотивация и исторический контекст 4
1.1.2 Модель коммуникации Шеннона–Уивера 5
1.1.3 Собственная информация 7

1.1.1. Теория информации: предмет, мотивация и исторический контекст

Теория информации — это раздел математики, возникший в середине XX века в ответ на инженерные и научные задачи передачи сообщений. Её цель состоит в том, чтобы количественно описать информацию и установить фундаментальные ограничения на её представление, сжатие и передачу. Классические вопросы, на которые пытается ответить теория информации, можно сформулировать следующим образом:

- как измерить количество информации в сообщении;
- каковы предельные возможности сжатия данных без потерь;
- как надёжно передавать сообщения по зашумлённым каналам;
- как связаны информация, случайность и неопределённость.

Но что есть информация? Слово *информация* происходит от латинского *informatio*, что означало «формирование образа, представления». Информация может передаваться, способна наделять знанием и обуславливать действия, обладать количественным измерением. Изначально оно описывало процесс превращения знания в структуру, которую можно осознать.

Современная теория информации берёт своё начало в работе К. Шеннона 1948 года, где была предложена математическая модель связи, позволившая отделить физические характеристики канала от абстрактной структуры сообщений. Существенным шагом было осознание того, что смысл передаваемых сообщений не играет роли при анализе предельных возможностей передачи. Именно такой отказ сделал возможным строгий количественный анализ.

Центральная идея теории информации состоит в том, что информация связана с *неопределённостью* исхода. Чтобы прояснить эту связь, полезно рассматривать информацию как меру изменения нашего знания о системе. До получения сообщения мы допускаем несколько возможных состояний мира; после получения сообщения множество допустимых состояний сокращается. Чем сильнее это сокращение, тем более информативным является сообщение.

Пример. Рассмотрим подбрасывание честной монеты. До эксперимента возможны два равновероятных исхода. После наблюдения результата неопределённость исчезает полностью. В этом смысле сообщение о результате подбрасывания монеты устраняет одну условную единицу неопределённости.

Если исход был практически предопределён заранее, то соответствующее сообщение не приводит к заметному изменению нашего знания.

Пример. Сообщение «завтра взойдёт солнце» практически не несёт информации, так как вероятность этого события до получения сообщения была близка к единице.

Иногда про информацию думают как про меру «удивительности» сообщения.

Пример. В городе “П” солнечная погода может быть только в августе, а во все остальные месяца погода пасмурная каждый день. Сообщение «Сегодня в городе “П” пасмурно» не несет никакой информации. В тоже время, более удивительное (поскольку более редкое) сообщение «Сегодня в городе “П” солнечно» сразу позволяет нам заключить что сегодня — август.

Такая интерпретация информации тесно связана с вероятностным описанием источника сообщений. Наши ожидания относительно возможных исходов естественным образом выражаются через вероятности. Маловероятные события оказываются более неожиданными и, следовательно, более информативными. Эта идея лежит в основе количественного определения информации, предложенного Шенноном.

Существует и другой, более алгоритмический взгляд на информацию. Интуитивно сообщение можно считать информативным, если его трудно описать короткой инструкцией. Например, последовательность из тысячи нулей легко описывается фразой «тысяча нулей подряд», тогда как случайная на вид двоичная строка той же длины не допускает столь компактного описания и требует перечисления почти всех символов. В этом смысле информация связана с минимальной длиной описания объекта.

Пример. Результат подбрасывания честной монеты можно передать одним битом. Результат броска честного кубика требует большего числа битов, так как число возможных исходов выше и ни один из них не выделен заранее.

Хотя в рамках курса мы не будем формализовывать этот алгоритмический подход, он тесно связан с вероятностной теорией информации и во многом дополняет её. В обоих случаях информация отражает отсутствие простоты, предсказуемости или сжатого описания.

1.1.2. Модель коммуникации Шеннона–Уивера

Первым, кто предложил рассматривать вопросы, связанные с информацией, независимо от её семантического содержания, был Клод Шеннон. Вместе с Уивером он занимался анализом процессов передачи информации, стремясь отделить математические свойства сообщений от их смысла. Для формального исследования передачи информации они предложили универсальную модель коммуникации, которая до сих пор служит фундаментом теории информации. Схема этой модели представлена на рис. 1.1.

Рис. 1.1: *Модель Шенонна-Уивера*

Модель включает пять основных компонентов, которые описывают полный цикл передачи информации:

- **Источник информации** — объект, генерирующий последовательность символов или сообщений. Источник может быть текстовым, аудио- или видеосигналом, результатом случайного эксперимента или любой другой дискретной последовательностью или функцией от времени.
- **Передатчик (кодирующее устройство)** — устройство или алгоритм, преобразующий сообщение в форму, пригодную для передачи по каналу. Кодирование здесь не связано с шифрованием, оно служит для представления информации так, чтобы её можно было надежно и эффективно передавать.
- **Канал/источник шума** — среда передачи сообщений, которая может вносить ошибки, искажения или задержки. Каналом может быть например оптоволоконный кабель или электромагнитное поле по которому распространяются радиоволны.
- **Приёмник (декодирующее устройство)** — устройство, восстанавливающее исходное сообщение из полученного сигнала. Основная задача декодера — точно восстановить исходное сообщение.
- **Получатель** — конечный адресат, для которого предназначено сообщение. В терминах модели именно получатель фиксирует информацию и измеряет её эффект на уменьшение неопределённости.

Смысл этой модели в том, что информацию можно измерять количественно, независимо от её содержания. Выход источника рассматривается как случайная величина с определённым распределением вероятностей. Каждое сообщение уменьшает неопределённость относительно исхода, а структура модели позволяет оценить, сколько информации реально передаётся и как её оптимально кодировать.

Пример. Рассмотрим источник, генерирующий буквы A и B с равными вероятностями (у каждого из символов вероятность 0.5). Передатчик кодирует символ A как 0, B как 1. Если канал идеален, приёмник восстанавливает сообщение без ошибок, и каждая буква передаёт одну битовую единицу информации. Если канал зашумлён, некоторые биты могут быть изменены случайным образом. Приёмник получает сигнал с неопределённостью, и задача кодера и декодера состоит в минимизации потерь информации и вероятности ошибки с помощью специальных кодов.

Следующий важный элемент модели — это понятие **сигнала**. Сигнал представляет собой физическую или математическую форму, в которой информация передаётся по каналу. Основное различие делается между дискретными и аналоговыми сигналами. Дискретные сигналы принимают конечное число значений. Примером служит последовательность битов в цифровом сообщении. Аналоговые сигналы непрерывны во времени и амплитуде, как звуковая волна или радиосигнал. Их передача требует дискретизации и квантования, чтобы можно было использовать цифровые методы обработки и кодирования.

Замечание. Квантование и дискретизация — это два процесса преобразования аналогового сигнала для цифровой обработки и передачи.

Дискретизация заключается в разбиении непрерывного по времени сигнала на отдельные моменты (выборки), фиксируя его значения через равные интервалы времени. Этот шаг делает сигнал «дискретным по времени» и позволяет работать с ним как с последовательностью отдельных измерений.

Квантование означает аппроксимацию непрерывных значений амплитуды каждой выборки конечным числом уровней. В результате амплитуда, которая изначально может принимать любое значение, заменяется ближайшим доступным уровнем, делая сигнал дискретным по амплитуде.

Более детальная классификация сигналов учитывает дискретность по времени и уровню амплитуды (квантование). Различают следующие виды сигналов:

- **Непрерывные (аналоговые) сигналы** — непрерывны по времени и амплитуде. Пример: чистый аналоговый радиосигнал. Для передачи таких сигналов используют аналоговые каналы или дискретизацию для цифровой обработки.
- **Дискретно-непрерывные сигналы** — дискретны по времени, амплитуда непрерывна. Пример: показания датчика, снятые через равные интервалы времени. Требует квантования для передачи по цифровому каналу.
- **Непрерывно-квантованные сигналы** — непрерывны по времени, амплитуда дискретизована. Пример: аналоговый сигнал с периодической выборкой и квантованием для цифровой передачи.
- **Дискретно-квантованные (цифровые) сигналы** — дискретны по времени и амплитуде. Пример: цифровой аудиопоток, последовательность битов в сети. Такие сигналы «легко» анализировать и кодировать.

На рис. 1.2 изображены различные формы представления одного и тоже аналогового сигнала.

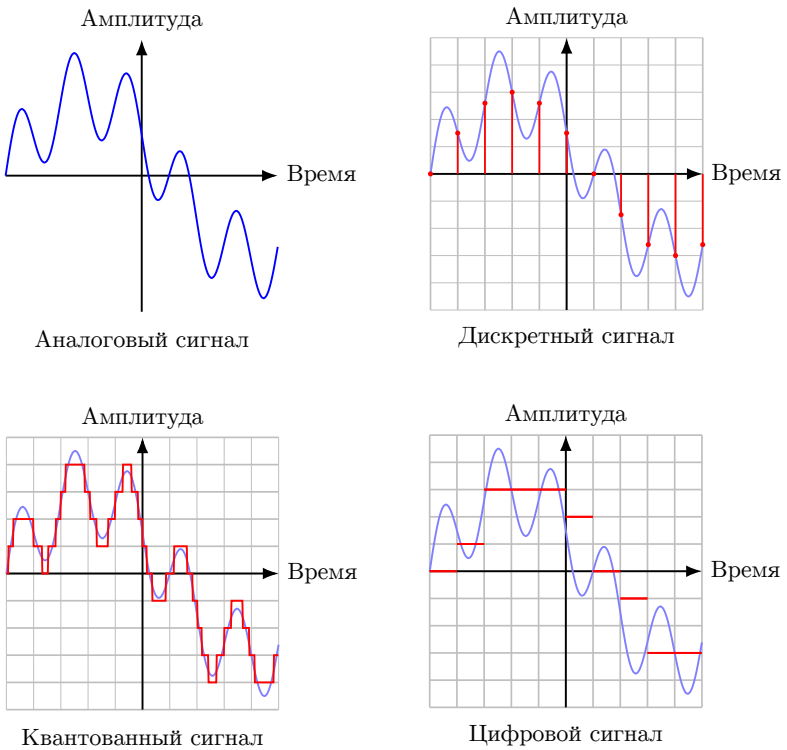

Рис. 1.2: *Виды сигналов*

Пример. Несколько примеров сигналов.

- Сигнал микрофона, подаваемый напрямую на усилитель без оцифровки, является аналоговым сигналом: и время, и амплитуда изменяются непрерывно.
- Температурный датчик, снимающий показания каждую секунду, создаёт дискретно-непрерывный сигнал. Значения температуры меняются непрерывно, но фиксируются через равные промежутки времени.
- Температурный датчик, передающий показания непрерывно, но с округлением до доли градуса, наоборот является примером источника квантованного сигнала.
- Цифровая аудиозапись в формате WAV является примером цифрового сигнала: звук оцифровывается с определённой частотой дискретизации и квантуется по амплитуде.

В рамках модели Шеннона–Уивера также можно выделить основные классы задач передачи сообщений:

- **Сжатие без потерь** — минимизация объёма передачи без потери информации. Используется, когда необходимо восстановить исходное сообщение точно.
- **Сжатие с потерями** — уменьшение объёма передачи с допустимой потерей деталей, например, для аудио- и видеосигналов.
- **Избыточное кодирование** — добавление дополнительных битов или структур, позволяющих обнаруживать и исправлять ошибки, возникающие в канале.

Давайте пока в качестве «toy model» рассмотрим случай цифрового сигнала и на его основе познакомимся с базовыми идеями теории информации.

1.1.3. Собственная информация

Пусть по каналу связи передаётся одно из заранее заданных сообщений $s_1, \ldots, s_k$. Предполагается, что сообщение s_i передаётся с вероятностью p_i. Каждому событию, состоящему в получении того или иного сообщения, мы хотим сопоставить числовую величину, называемую *собственной информацией* этого события.

Интуитивно ясно, что редкое сообщение должно нести больше информации, чем частое: получение почти гарантированного исхода мало что сообщает получателю, тогда как маловероятный исход существенно сокращает неопределённость. Эти соображения формализуются в виде следующих аксиом.

Аксиомы собственной информации. Пусть A — случайное событие. Функция $\mathcal{I}(A)$, измеряющая информацию, должна удовлетворять условиям:

1. **Неотрицательность:** $\mathcal{I}(A) \geq 0$ для любого события A с положительной вероятностью;
2. **Монотонность:** при увеличении вероятности $\mathbb{P}(A)$ величина $\mathcal{I}(A)$ убывает;
3. **Аддитивность:** для *независимых* событий A и B

$$\mathcal{I}(A \cap B) = \mathcal{I}(A) + \mathcal{I}(B).$$

Эти требования отражают базовые свойства информации: она не может быть отрицательной, уменьшается для более ожидаемых событий и суммируется при независимом объединении источников неопределённости.

Замечание. При этом еще одно требование, уже не столь естественное — чтобы из равенства $\mathbb{P}(A) = \mathbb{P}(B)$ следовало равенство $\mathcal{I}(A) = \mathcal{I}(B)$. Иначе говоря, информация зависит только от вероятности события. Может показаться странным, что мы оцениваем информацию, не учитывая семантику событий. Однако если в примере из начала положить $s_1 = \text{"0"}, s_2 = \text{"1"}$ (т.е. по каналу передаётся один бит), то в ситуации, когда символы равновероятны, сообщение “0” будет настолько «удивительным», насколько сообщение “1”.

Следующий результат показывает, что выбранные аксиомы практически однозначно определяют вид функции собственной информации.

Единственность функции собственной информации

Теорема 1.1.1 (Единственность функции собственной информации)**.** *Существует единственная (с точностью до умножения на неотрицательную константу) непрерывная функция $\mathcal{I}(A)$, зависящая только от вероятности события $\mathbb{P}(A)$ и удовлетворяющая аксиомам 1–3.*

Для доказательства этой теоремы потребуется вспомогательная лемма.

Лемма 1.1.2. *Пусть $f\colon \mathbb{R}_+ \to \mathbb{R}$ непрерывная и для любых $x, y \in \mathbb{R}_+$ выполнено равенство:*

$$f(x+y) = f(x) + f(y) \tag{1.1}$$

Тогда $f(x) = cx$ для некоторого $c \in \mathbb{R}$.

Доказательство. Заметим, что в силу 1.1 для любого $x \in \mathbb{R}_+$ и для любого $n \in \mathbb{N}$ имеем:

$$f(nx) = f(x) + f((n-1)\cdot x) = \ldots = n \cdot f(x)\,.$$

Применяя это равенство к $x = \frac{y}{m}$, где $y \in \mathbb{R}_+$ и для любого $m \in \mathbb{N}$ получаем что:

$$f(y) = f\Big(m \cdot \frac{y}{m}\Big) = mf\Big(\frac{y}{m}\Big) \quad \Rightarrow \quad f\Big(\frac{y}{m}\Big) = \frac{1}{m} f(y)$$

Таким образом для любых $n, m \in \mathbb{N}$ и для любого $x \in \mathbb{R}$:

$$f\Big(\frac{n}{m}x\Big) = \frac{n}{m} f(x)$$

Положим $c = f(1)$. Докажем что $f(x) = cx$. Пусть $\{q_i\}_{i=1}^{+\infty}, q_i = \frac{n_i}{m_i}, n_i, m_i \in \mathbb{N}$ — последовательность рациональных чисел, такая что $q_i \xrightarrow[n\to+\infty]{} x$. По непрерывности f:

$$f(q_i) \xrightarrow[n\to+\infty]{} f(x)$$

С другой стороны, в силу доказанного ранее, $f(q_i) = q_i f(1) = c \cdot q_i$. Откуда

$$cx = \lim_{i\to+\infty} (c \cdot q_i) = f(x)$$

□

Доказательство теоремы. Аддитивность (аксиома 3) для независимых событий означает, что для любых $p, q \in (0, 1]$ должно выполняться

$$\mathcal{I}(pq) = \mathcal{I}(p) + \mathcal{I}(q),$$

где $I(p)$ обозначает информацию события вероятности p. Рассмотрим $f(t) = \mathcal{I}(\exp(-t))$:

$$f(t_1 + t_2) = f(t_1) + f(t_2)$$

И значит $f(t) = ct$ по лемме 1.1.2. Тогда, поскольку $\mathcal{I}$ монотонна (аксиома 2)

$$\mathcal{I}(\exp(-t)) = ct \Rightarrow \mathcal{I}^{-1}(ct) = \exp(-t) \Rightarrow \mathcal{I}^{-1}(t) = \exp\left(-\frac{t}{c}\right) \Rightarrow \mathcal{I}(p) = -c \ln p$$

□

Замечание. На самом деле, непрерывность в формулировке теоремы 1.1.1 (и леммы 1.1.2) избыточна и достаточна только монотонность.

Таким образом, аксиоматический подход естественным образом приводит к логарифмической шкале измерения информации.

Определение 1.1.3 (Собственная информация события)**.** Собственной информацией события A с вероятностью $\mathbb{P}(A)$ называется величина

$$\mathcal{I}_m(A) = -\log_m \mathbb{P}(A),$$

где $m > 1$ — положительная константа.

Замечание. Выбор основания логарифма определяет единицы измерения информации: при основании 2 информация измеряется в битах, при основании e — в натах. Далее, если не оговорено иное, будем использовать логарифмы по основанию 2 и обозначать $\mathcal{I} = \mathcal{I}_2$.

Рассмотрим несколько простых ситуаций, иллюстрирующих введённое определение.

Пример (Честная монета)**.** Подбрасывается честная монета. Возможны два исхода: орёл O и решка R, причём

$$\mathbb{P}(O) = \mathbb{P}(R) = 0.5.$$

Собственная информация каждого исхода равна

$$\mathcal{I}(O) = \mathcal{I}(R) = -\log_2 0.5 = 1 \text{ бит}.$$

Получение любого исхода полностью устраняет неопределённость относительно результата броска.

Пример (Нечестная монета)**.** Пусть монета выпадает орлом с вероятностью 0.8 и решкой с вероятностью 0.2. Тогда

$$\mathcal{I}(O) = -\log_2 0.8 \approx 0.32 \text{ бита}, \qquad \mathcal{I}(R) = -\log_2 0.2 \approx 2.32 \text{ бита}.$$

Редкий исход (решка) несёт существенно больше информации, чем ожидаемый.

1.2. Энтропия

Оглавление

1.2.1 Понятие об опыте. Энтропия Шеннона . . . 9
1.2.2 Неравенство Гиббса. Оценки энтропии . . . 9
Приложение. О различных смыслах энтропии . . . 10
Приложение. Неравенство Йенсена . . . 12

Ранее мы рассматривали собственную информацию отдельных событий. Теперь перейдём к полным системам событий, описывающим исходы некоторого случайного опыта/эксперимента.

1.2.1. Понятие об опыте. Энтропия Шеннона

Определение (Случайный опыт)**.** *Под случайным опытом понимается конечная система непересекающихся событий*

$$\mathcal{A} = \{A_1, \dots, A_n\}, \quad A_i \cap A_j = \varnothing,\ i \neq j, \quad \bigsqcup_{i=1}^{n} A_i = \Omega,$$

где Ω — пространство элементарных исходов, $\mathbb{P}(A_i) > 0, i = 1, \dots n$. События A_i называются результатами или исходами такого опыта.

Замечание. Данное определение не является конвенциональным, хотя встречается в литературе. Мы используем его только в рамках данного курса, чтобы не писать каждый раз «полная система событий».

Для полной системы событий естественно определить следующую величину:

Определение 1.2.1 (Энтропия случайного опыта)**.** *Энтропией* случайного опыта $\mathcal{A} = \{A_1, \dots, A_n\}$ называется средняя собственная информация результата опыта:

$$\mathrm{H}_m(\mathcal{A}) = \sum_{i=1}^{n} \mathbb{P}(A_i) \cdot \mathcal{I}_m(A_i) = -\sum_{i=1}^{k} p_i \log_m p_i.$$

Замечание. Как и ранее, если нижний индекс опускается, подразумевается логарифм по основанию 2, $\mathrm{H}(\cdot) = \mathrm{H}_2(\cdot)$

Пример (Честная монета)**.** Случайный опыт $\mathcal{A} = \{O, R\}$, $\mathbb{P}(O) = \mathbb{P}(R) = 0.5$:

$$\mathrm{H}(\mathcal{A}) = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1 \text{ бит}.$$

Пример (Нечестная монета)**.** Случайный опыт $\mathcal{A} = \{O, R\}$, $\mathbb{P}(O) = 0.8$, $\mathbb{P}(R) = 0.2$:

$$\mathrm{H}(\mathcal{A}) = -(0.8 \log_2 0.8 + 0.2 \log_2 0.2) \approx 0.72 \text{ бита}.$$

Нотация. $\mathrm{H}_m(p_1, \dots, p_n)$ будет обозначать энтропию Шеннона для некоторого опыта, результаты которого имеют вероятности $p_1, \dots, p_n$.

1.2.2. Неравенство Гиббса. Оценки энтропии

Неравенство Гиббса

Лемма 1.2.2 (Неравенство Гиббса)**.** *Для любых двух наборов чисел $p_1, \dots, p_n$ и $q_1, \dots, q_n$ в полуинтервале $(0; 1]$, таких что:*

$$\sum_{i=1}^{n} p_i = 1, \quad \sum_{i=1}^{n} q_i \leq 1,$$

и для любого вещественного $m > 1$ выполнено неравенство:

$$-\sum_{i=1}^{n} p_i \log_m p_i \leq -\sum_{i=1}^{n} p_i \log_m q_i \tag{1.2}$$

Причем равенство достигается тогда и только тогда, когда $q_i = p_i$ для всех $i = 1, \dots, n$

Доказательство. Не умаляя общности $m = 2$. Перепишем неравенство (1.2) в следующем виде:

$$\sum_{i=1}^{n} p_i \log \frac{q_i}{p_i} \leq 0$$

Дальше, поскольку log — вогнутая функция, то по неравенству Йенсена имеем:

$$\sum_{i=1}^{n} p_i \log \frac{q_i}{p_i} \leq \log\left(\sum_{i=1}^{n} p_i \cdot \frac{q_i}{p_i}\right) = \log\left(\sum_{i=1}^{n} q_i\right) \leq \log(1) \leq 0$$

Теперь рассмотрим случай равенства. Из случай равенства в неравенстве Йенсена имеем что:

$$\frac{p_1}{q_1} = \ldots = \frac{p_n}{q_n} = \gamma$$

И значит $\sum p_i = \gamma \sum q_i$. С другой стороны $\sum q_i = 1$ — это следует из второго неравенства. □

Теорема 1.2.3 (О значениях энтропии)**.** *Для любых $p_1, \ldots, p_n \in [0; 1]$ таких что $\sum_{i=1}^{n} p_i = 1$ верно что*

$$0 \leq \mathrm{H}_m(p_1, \ldots, p_n) \leq \log_m n$$

Причем:

- *Равенство $\mathrm{H}_m(p_1, \ldots, p_n) = 0$ достигается тогда и только тогда, когда одна из вероятностей p_i равна 1.*
- *Равенство $\mathrm{H}_m(p_1, \ldots, p_n) = \log_m n$ достигается тогда и только тогда, когда все вероятности $p_i = \frac{1}{n}, i = 1, \ldots n$.*

Доказательство. Не умаляя общности $m = 2$.

Нижняя граница. Понятно что поскольку $-p \log p \geq 0$ для всякого $p \in [0; 1]$[1], величина H неотрицательна как сумма неотрицательных величин. Пусть теперь $\mathrm{H}(p_1, \ldots, p_n) = 0$. Понятно тогда что

$$p_1 \log p_1 = \ldots = p_n \log p_n = 0 \quad \Leftrightarrow \quad \forall i = 1, \ldots, n \; p_i \in \{0, 1\}$$

С учетом того что $p_1 + \ldots + p_n = 1$, получаем что ровно одно значение p_i равно 1, все остальные — 0.

Верхняя граница. По неравенству Гиббса с $q_i = \frac{1}{n}$:

$$-\sum_{i=1}^{n} p_i \log p_i \leq -\sum_{i=1}^{n} p_i \log \frac{1}{n} = -\log \frac{1}{n} \cdot \underbrace{\sum_{i=1}^{n} p_i}_{1} = \log n$$

Причем, в силу случая равенства в лемме 1.2.2, равенство достигается только при $p_i = \frac{1}{n}$. □

Приложение. О различных смыслах энтропии

Что на самом деле измеряет энтропия? Довольно часто на этот вопрос дают такой ответ: энтропия — мера неопределённости. Однако, этот ответ во-первых весьма туманен, а во-вторых слово *неопределённость* само по себе носит не вполне определённый смысл. Конечно, у нас есть интерпретация с точки зрения теории информации: для события A его собственная информация $\mathcal{I}(A)$ это объём/длина сообщения, которым мы бы могли описать, что это событие произошло. В свою очередь энтропия опыта с несколькими исходами — усреднённое по вероятности значение собственной информации:

$$\mathrm{H}(X) = -\sum_{i} p_i \log_2 p_i,$$

где p_i — вероятность i-го исхода. Но такая трактовка тоже не до конца ясна: для бинарного события сообщение, фиксирующее его исход, всегда будет иметь размер 1 бит, независимо от вероятности. Так почему же собственная информация события для нечестного броска монетки будет меньше одного бита (и энтропия тоже)? Тут на помощь приходит асимптотический анализ: оказывается, что если взять достаточно большое число бросков нечестной монеты и выписать в ряд результаты, например

OPOOPPPPPPPOPPPPOPPPPPPP,

то окажется, что если кодировать не каждый символ по отдельности, а, скажем, блоки из трёх символов, то последовательность можно сжать. Причём при самом эффективном сжатии удельная длина символа при росте блока будет

[1] Здесь и далее, принято соглашение, что $0 \cdot \log 0 = 0$.

пропорциональна $-\log_2$ его вероятности. Это в некотором смысле объясняет, как же информация может быть нецелым числом: в среднем на один символ можно «экономить» часть бита, хотя отдельный символ требует целого бита.

Однако привязка к теории кодирования несколько неудобна, поскольку ограничивает наши способности к обобщению; в частности, на непрерывный случай. Оказывается, что энтропия имеет физический смысл. В первую очередь, она является прямым аналогом и обобщением термодинамической энтропии. Чтобы понять её суть представим себе следующее. Пускай есть некоторая кристаллическая решетка, находящаяся в состоянии термодинамического равновесия, в частности, имеющая некоторую стабилизированную температуру. Будем считать что пока есть только один параметр — температура. Тогда значение температуры определяет *макросостояние* системы. С другой стороны, температура обеспечивается за счет колебаний частиц формирующих решетку; каждая отдельная частица решетки колеблется с частотой из некоторого дискретного набора; полное описание такой системы вида «частица»–«частота колебания» составляет *микросостояние* системы. Одному макросостоянию отвечает множество разных микросостояний, реализующих его. Энтропия Больцмана определяется как

$$S = k_B \ln W,$$

где W — число микросостояний, реализующих данное макросостояние. Однако такое определение корректно для ситуации термодинамического равновесия, когда все микросостояния равновероятны. Обобщение на ситуацию произвольных вероятностей микросостояний было предложено Гиббсом:

$$S_{\text{Гиббса}} = -k_B \sum_i p_i \ln p_i,$$

где p_i — вероятность i-ого микросостояния. При измерении в битах (делении на $k_B \ln 2$) энтропия Гиббса даёт формулу Шеннона:

$$\mathrm{H} = \frac{S_{\text{Гиббса}}}{k_B \ln 2}.$$

В этом контексте энтропия Шеннона измеряет *априорный* «объём» нашего незнания о точном микроскопическом состоянии системы при известных макроскопических параметрах. Чем больше возможных микросостояний (конфигураций) совместимо с нашими наблюдениями, тем выше неопределённость (энтропия) и тем больше информации мы получим, узнав точное состояние системы. Внезапно, эта точка зрения довольно тесно перекликается с теорией вероятности. Мы можем считать, что и «микросостояния» — это элементы полной системы событий $\mathcal{A}$, описывающей различные уровни «энергии», иначе говоря, различные микросостояния системы. Тогда, с точностью до константы, энтропия Шеннона и энтропия Гиббса совпадают.

В этом смысле, энтропию можно понимать как меру дезорганизации, сложности или информационной ёмкости системы. Физическая система с низкой энтропией (например, кристаллическая решётка при абсолютном нуле или выстроенный в линию газ) является высокоорганизованной и предсказуемой: зная положение одной молекулы, можно с высокой уверенностью предсказать положение соседней. Сообщение о её состоянии будет коротким. Система с высокой энтропией (газ в равновесии, хаотичная структура) максимально неупорядочена и непредсказуема — для точного описания её конфигурации потребуется огромное количество информации. Таким образом, физический процесс увеличения термодинамической энтропии в изолированной системе соответствует стиранию различий и переходу к более «типичному», а значит, и более вероятному с информационной точки зрения состоянию, которое описывается большим числом бит.

Приложение. Неравенство Йенсена

Теорема (Неравенство Йенсена)**.** *Пусть $f(x)\colon E \to \mathbb{R}$, $E = \langle a; b\rangle \subset \mathbb{R}$ — выпуклая функция. Тогда для любых точек $x_1, \ldots, x_n \in E$, и любых чисел $p_1, \ldots, p_n \in (0;1)$ таких, что $\sum_{i=1}^n p_i = 1$, выполнено неравенство:*

$$f\left(\sum_{i=1}^n p_i x_i\right) \geq \sum_{i=1}^n p_i f(x_i) \tag{1.3}$$

Причем равенство достигается тогда и только тогда, когда:

1. *либо все точки x_i равны некоторому $x_0 \in E$;*
2. *либо функция f линейна*[2] *на некотором отрезке E' содержащем все точки x_i.*

Доказательство. Для случая $n = 2$ неравенство (1.3) есть определение выпуклой функции. Покажем что, если для каких-то $p_1, p_2 \in (0;1), p_1 + p_2 = 1$ неравенство обратилось в равенство, то f будет линейна на соответствующем отрезке[3]. Не умаляя общности, пусть $x_1 < x_2, p_1 = p, p_2 = 1 - p, p \in (0;1)$. И пусть:

$$f(px_1 + (1-p)x_2) = pf(x_1) + (1-p)f(x_2)$$

Рассмотрим функцию

$$g(x) = (x - x_1)\frac{f(x_2) - f(x_1)}{x_2 - x_1}$$

Имеем:

1. $g(x)$ линейная функция из $E' = [x_1, x_2]$ в $\mathbb{R}$;
2. $g(x_1) = f(x_1)$, $g(x_2) = f(x_2)$ и для всех точек $x \in E'$ $f(x) \geq g(x)$
3. $d(x) = f(x) - g(x)$ — выпуклая функция.

Пункты 2 и 3 легко проверить по определению выпуклой функции. Итак, обозначим $x^* = px_1 + (1-p)x_2 \in E'$. Тогда имеем что $d(x_1) = d(x_2) = d(x^*) = 0$. С другой стороны, если $f(x)$ нелинейна, то $f(x)$ строго больше $g(x)$ хотя бы в одной точке. Не умаляя общности, пусть это точка $\hat{x} \in (x_1; x^*)$. Тогда для некоторого $\lambda \in (0;1)$ верно что $x^* = \lambda\hat{x} + (1-\lambda)x_2$. Но тогда, в силу выпуклости d:

$$0 = d(x^*) = d(\lambda\hat{x} + (1-\lambda)x_2) \leq \lambda d(\hat{x}) + (1-\lambda)d(x_2) = \lambda \cdot d(\hat{x}) > 0\,.$$

Противоречие и значит $f(x) = g(x)$ для всех $x \in E'$.

Покажем теперь неравенство для произвольного n. Для этого воспользуемся математической индукцией с уже доказанной базой $n = 2$. Считая, что неравенство доказано для любых наборов точек размера $n - 1$, рассмотрим произвольный набор из n точек $x_1 \leq x_2 \leq \ldots \leq x_n$. Положим

$$\begin{aligned} &y_1 = x_1, \quad q_1 = p_1 \\ &y_2 = \frac{p_2x_2 + \ldots + p_nx_n}{p_2 + \ldots + p_n}, \quad q_2 = 1 - q_1 \end{aligned}$$

По определению выпуклости имеем что

$$f\left(\sum_{i=1}^n p_i x_i\right) = f(q_1y_1 + q_2y_2) \geq q_1f(y_1) + q_2f(y_2) = p_1f(x_1) + (p_2 + \ldots + p_n)f\left(\frac{1}{(p_2 + \ldots + p_n)}\sum_{i=2}^n p_ix_i\right)$$

Применяя ко второму слагаемому индукционое предположение

$$\geq p_1f(x_1) + \sum_{i=2}^n p_if(x_i) = \sum_{i=1}^n p_if(x_i)$$

Что и требовалось доказать. Случай равенства разбирается аналогично $n = 2$ — все неравенства выше обращаются в равенства и из этого получается что f линейна на $[x_1, x_n]$. □

[2] Везде и далее более правильно говорить аффинная: т.е. $f(x) = ax + b$ для некоторых $a, b \in \mathbb{R}$.

[3] Случай равенства $x_1 = x_2$ в силу его тривиальности

1.3. Условная и совместная энтропия

Оглавление

1.3.1 Совместная и условная собственная информация . . . 13
1.3.2 Условная энтропия. . . . 14
1.3.3 Совместная энтропия . . . 16
1.3.4 Вариации на тему правила цепочки . . . 18

1.3.1. Совместная и условная собственная информация

В реальных задачах часто приходится иметь дело не с одиночными событиями, а с их комбинациями и зависимостями. Для этого вводятся понятия совместной и условной информации.

Определение 1.3.1. Пусть A и B — два события, $\mathbb{P}(A \cap B) > 0$. Совместной информацией событий A и B называется собственная информация пересечения:

$$\mathcal{I}_m(A, B) = \mathcal{I}_m(A \cap B).$$

Условной информацией события A при условии события B называется величина:

$$\mathcal{I}_m(A \mid B) = -\log \mathbb{P}(A \mid B).$$

Нотация. $\mathcal{I}_m(A_1, \ldots, A_n) = \mathcal{I}_m(A_1 \cap \ldots \cap A_n)$

Нотация. $\mathcal{I}_m(A \mid B_1, \ldots, B_n) = \mathcal{I}_m(A \mid B_1 \cap \ldots \cap B_n)$

Предложение. *Пусть A и B — два события, $\mathbb{P}(A \cap B) > 0$.*

$$\mathcal{I}_m(A \mid B) = \mathcal{I}_m(A) + \mathcal{I}_m(B \mid A) = \mathcal{I}_m(B) + \mathcal{I}_m(A \mid B).$$

Доказательство. Не умаляя общности $m = 2$. Распишем по определению:

$$\mathcal{I}(A \cap B) = \log \mathbb{P}(A \cap B) = \log(\mathbb{P}(A) \cdot \mathbb{P}(A \mid B)) = \log \mathbb{P}(A) + \log \mathbb{P}(A \mid B) = \mathcal{I}(B) + \mathcal{I}(A \mid B)$$

□

Пример (Два независимых броска монеты)**.** Пусть O_1 — событие выпадения орла при первом броске честной монеты, а O_2 — аналогичное событие для второго броска. Имеем

$$\mathbb{P}(O_1) = \mathbb{P}(O_2) = 0.5,$$

причём события независимы. Тогда

$$\mathcal{I}(O_1, O_2) = \mathcal{I}(O_1) + \mathcal{I}(O_2) = 1 + 1 = 2 \text{ бита}.$$

Пример (Зависимые события)**.** Рассмотрим следующую модель: первый бросок монеты честный, а второй полностью определяется первым. Если в первом броске выпал орёл, то во втором обязательно выпадает решка, и наоборот. Тогда

$$\mathbb{P}(O_1) = \mathbb{P}(R_1) = 0.5.$$

Собственная информация первого броска равна $\mathcal{I}(O_1) = 1$ бит, а условная информация второго броска при известном первом исходе равна

$$\mathcal{I}(R_2 \mid O_1) = -\log 1 = 0.$$

Следовательно,

$$\mathcal{I}(R_2 \mid O_1) = 1 \text{ бит}.$$

Пример (Последовательность символов)**.** Пусть источник независимо генерирует символы a, b, c с вероятностями

$$\mathbb{P}(a) = 0.5, \quad \mathbb{P}(b) = 0.25, \quad \mathbb{P}(c) = 0.25.$$

Для последовательности abc

$$\mathbb{P}(abc) = 0.03125, \qquad \mathcal{I}(a, b, c) = 5 \text{ бит}.$$

Если получены только первые два символа,

$$\mathcal{I}(a, b) = 3 \text{ бита}.$$

1.3.2. Условная энтропия.

Здесь и далее, речь идет о нескольких опытах сразу. Пусть имеются два опыта

$$\mathcal{A} = \{A_1, \dots, A_{n_a}\} = \{A_{i_a}\}_{i=1}^{n_a}, \quad \mathcal{B} = \{B_1, \dots, B_{n_b}\} = \{B_{i_b}\}_{i_b=1}^{n_b},$$

Для простоты обозначений, мы будем считать что с каждым опытом связан свой индекс. В частности, для опыта $\mathcal{A}$ вероятности исходов $\mathbb{P}(A_{i_a}), i_a = 1, \dots, n_a$ мы будем обозначать за p_{i_a}, а для опыта $\mathcal{B}$ — вероятности $\mathbb{P}(B_{i_b}), i_b = 1, \dots, n_b$ обозначим за p_{i_b}.

Замечание. Из-за такого злоупотребления обозначениями (abuse of notation), формально запись p_1 обозначает непонятно что. Но таких обозначений далее не будет.

Определение 1.3.2 (Условная энтропия)**.** Пусть $p_{i_b|i_a} = \mathbb{P}(B_{i_b} \mid A_{i_a})$. Условная энтропия опыта $\mathcal{B}$ относительно опыта $\mathcal{A}$ определяется как

$$\mathrm{H}_m(\mathcal{B} \mid \mathcal{A}) = \sum_{i_a=1}^{n_a} \mathbb{P}(A_{i_a}) \sum_{i_b=1}^{n_b} \mathbb{P}(B_{i_b} \mid A_{i_a}) \mathcal{I}_m(B_{i_b} \mid A_{i_a}) = -\sum_{i_a=1}^{n_a} p_{i_a} \sum_{i_b=1}^{n_b} p_{i_b|i_a} \log_m p_{i_b|i_a}.$$

Предложение 1.3.3. *Для любых двух опытов $\mathcal{A}$ и $\mathcal{B}$ выполнено:*

$$0 \le \mathrm{H}_m(\mathcal{B} \mid \mathcal{A}) \le \mathrm{H}_m(\mathcal{B})$$

Причем:

- *равенство $\mathrm{H}_m(\mathcal{B} \mid \mathcal{A}) = \mathrm{H}_m(\mathcal{B})$ достигается тогда и только тогда, когда любые два события $A \in \mathcal{A}, B \in \mathcal{B}$ независимы;*
- *равенство $\mathrm{H}_m(\mathcal{B} \mid \mathcal{A}) = 0$ достигается тогда и только тогда, когда для любых событий $A \in \mathcal{A}, B \in \mathcal{B}$, выполнено $\mathbb{P}(B \mid A) \in \{0, 1\}$.*

Доказательство. Не умаляя общности $m = 2$.

Нижняя граница. Следует из того что каждое слагаемое неотрицательно. Рассмотрим случай равенства: имеем что

$$\text{Для любых } i_a = 1, \dots n_a,\ i_b = 1, \dots, n_b \ :\ p_{i_a} p_{i_b|i_a} \log p_{i_b|i_a} = 0$$

Откуда возможны три случая:

1. $p_{i_a} = 0$;
2. $p_{i_b|i_a} = 0$;
3. $\log p_{i_b|i_a} = 0$, т.е. $p_{i_b|i_a} = 1$.

Первый случай невозможен по определению опыта. Откуда получаем что $p_{i_b|i_a} \in \{0, 1\}$, что и требовалось.

Верхняя граница. Воспользуемся неравенством Гиббса (лемма 1.2.2)

$$-\mathrm{H}(\mathcal{B} \mid \mathcal{A}) = \sum_{i_a=1}^{n_a} p_{i_a} \overbrace{\sum_{i_b=1}^{n_b} p_{i_b|i_a} \log p_{i_b|i_a}}^{\ge \sum_{i_b=1}^{n_b} p_{i_b|i_a} \log p_{i_b}} \ge \sum_{i_a=1}^{n_a} p_{i_a} \sum_{i_b=1}^{n_b} p_{i_b|i_a} \log p_{i_b} =$$

$$= \sum_{i_a=1}^{n_a} \sum_{i_b=1}^{n_b} \underbrace{p_{i_a} p_{i_b|i_a}}_{p_{i_b} p_{i_a|i_b}} \log p_{i_b} = \sum_{i_b=1}^{n_b} p_{i_b} \log p_{i_b} \underbrace{\sum_{i_a=1}^{n_a} p_{i_a|i_b}}_{1} = -\mathrm{H}(\mathcal{B})$$

Откуда получаем что $\mathrm{H}(\mathcal{B}|\mathcal{A}) \le \mathrm{H}(\mathcal{A})$. Рассмотрим случай равенства. Так как доказательство верхней оценки применяет неравенство Гиббса к n_a суммам, случай равенства означает что *для любого* $i_a = 1, \dots, n_a$ выполнено равенство:

$$\sum_{i_b=1}^{n_b} p_{i_b|i_a} \log p_{i_b|i_a} = \sum_{i_b=1}^{n_b} p_{i_b|i_a} \log p_{i_b}.$$

Из этого как известно следует что $p_{i_b|i_a} = p_{i_b}$, что и означает что для любых $A \in \mathcal{A}, B \in \mathcal{B}$, события A и B независимы; □

Пример (Случайная монета)**.** Рассмотрим опять модель броска монетки. Пусть наугад выбирается монета: с вероятностью $\frac{1}{2}$ она честная, с вероятностью $\frac{1}{2}$ она фальшивая и выпадает всегда одной стороной — для определенности скажем что решкой. Можем рассмотреть два опыта: первый состоит в наблюдении первого броска монеты и имеет

два результата, $\mathcal{A}_1 = \{O_1, P_1\}$. Второй состоит в наблюдении второго броска монеты и также имеет два результата, $\mathcal{A}_2 = \{O_2, P_2\}$. Нетрудно вычислить вероятности событий: $\mathbb{P}(O_1) = \mathbb{P}(O_2) = \frac{1}{4}$, $\mathbb{P}(P_1) = \mathbb{P}(P_2) = \frac{3}{4}$ и значит:

$$\mathrm{H}(\mathcal{A}_1) = \mathrm{H}(\mathcal{A}_2) = -\frac{3}{4}\log_2\frac{3}{4} - \frac{1}{4}\log_2\frac{1}{4}$$

С другой стороны в среднем наблюдение первого броска снижает нашу неопределенность в вопросе фальшивости монеты — как минимум, если при первом броске выпал орёл то монетка заведомо честная. Поэтому:

$$\mathrm{H}(\mathcal{A}_2 \mid \mathcal{A}_1) = -\frac{3}{4}\left(\frac{3}{4}\log_2\frac{3}{4} + \frac{1}{4}\log_2\frac{1}{4}\right) - \frac{1}{4}\left(\frac{1}{2}\log_2\frac{1}{2} + \frac{1}{2}\log_2\frac{1}{2}\right)$$

Определение 1.3.4 (Независимость опытов)**.** Два опыта $\mathcal{A}$ и $\mathcal{B}$ называются независимыми, если любая пара результатов $A \in \mathcal{A}$ и $B \in \mathcal{B}$ суть независимые события.

Замечание. Таким образом $\mathrm{H}(\mathcal{B} \mid \mathcal{A}) = \mathrm{H}(\mathcal{B})$ тогда и только тогда, когда опыты $\mathcal{A}$ и $\mathcal{B}$ независимы.

Определение 1.3.5. Будем говорить что опыт $\mathcal{B}$ определяется опытом $\mathcal{A}$ если для любых событий $A \in \mathcal{A}, B \in \mathcal{B}$, выполнено что $\mathbb{P}(B \mid A) \in \{0, 1\}$.

Замечание. Таким образом $\mathrm{H}(\mathcal{B} \mid \mathcal{A}) = 0$ тогда и только тогда, когда опыт $\mathcal{A}$ определяет опыт $\mathcal{B}$.

Замечание. Почему такое определение естественно? Оказывается что если опыт $\mathcal{B}$ определяется опытом $\mathcal{A}$, то для любого A_{i_a} результата опыта $\mathcal{A}$ существует ровно один результат $B_{r(i_a)}$ опыта $\mathcal{B}$, такой что $\mathbb{P}(B_{r(i_a)} \mid A_{i_a}) = 1$; Это следует из того что:

$$\sum_{i_b=1}^{n_b} \mathbb{P}(B_{i_b} \mid A_{i_a}) = 1$$

Поэтому зная результат опыта $\mathcal{A}$ можно достоверно предсказать результат опыта $\mathcal{B}$.

Пример (Два броска монеты)**.** Пусть $\mathcal{A}_1 = \{O_1, P_1\}$ и $\mathcal{A}_2 = \{O_2, P_2\}$ — два опыта состоящие в броске монеты. Если броски независимы и монета честная, то:

$$\mathrm{H}(\mathcal{A}_1) = \mathrm{H}(\mathcal{A}_1 \mid \mathcal{A}_2) = 1 \text{ бит}, \quad \mathrm{H}(\mathcal{A}_2) = \mathrm{H}(\mathcal{A}_2 \mid \mathcal{A}_1) = 1 \text{ бит}.$$

Если второй бросок полностью зависит от первого (например, всегда противоположен первому), то

$$\mathrm{H}(\mathcal{B} \mid \mathcal{A}) = \mathrm{H}(\mathcal{A} \mid \mathcal{B}) = 0 \text{ бит}.$$

Аналогично тому как вводится понятие независимости в совокупности для событий[4], можно ввести понятие независимых в совокупности опытов.

Определение 1.3.6 (Независимость опытов в совокупности)**.** Опыты $\mathcal{A}_1, \ldots \mathcal{A}_r$ называются независимыми в совокупности, если для любого поднабора $\mathcal{A}_{j_1}, \ldots, \mathcal{A}_{j_k}$ любые события $A_1 \in \mathcal{A}_{j_1}, \ldots A_k \in \mathcal{A}_{j_k}$ будут независимыми в совокупности.

Замечание. Определение можно упростить: $\mathcal{A}_1, \ldots \mathcal{A}_r$ называются независимыми в совокупности, если для любого поднабора $\mathcal{A}_{j_1}, \ldots, \mathcal{A}_{j_k}$ и любых событий $A_1 \in \mathcal{A}_{j_1}, \ldots A_k \in \mathcal{A}_{j_k}$:

$$\mathbb{P}(A_1 \cap \ldots \cap A_k) = \mathbb{P}(A_1) \cdot \ldots \cdot \mathbb{P}(A_k)$$

Так как равенство выполнено для любых наборов событий $(A_1, \ldots, A_k)$ из разных опытов, то в частности выполнено для любого поднабора.

Пример. Пусть честная монетка независимо бросается r раз. Обозначим за O_i (соотв. P_i), $i = 1, \ldots r$ событие «*при i-ом броске выпал(а) орёл (решка)*». Рассмотрим следующие опыты:

$$\begin{aligned} &\mathcal{A}_i = \{O_i, P_i\}, \quad i = 1, \ldots, r \\ &\mathcal{A}_0 = \{T_0, T_1\}, \quad T_0 \text{ — число выпавших орлов чётно, } T_1 \text{ — нечетно} \end{aligned}$$

Тогда опыты $\mathcal{A}_1, \ldots, \mathcal{A}_r$ независимы в совокупности, а если добавить к ним $\mathcal{A}_0$, то независимость в совокупности пропадёт и останется только попарная независимость[5].

[4] И для случайных величин

[5] Проверьте

1.3.3. Совместная энтропия

Определение 1.3.7 (Совместная энтропия)**.** Пусть $p_{i_a i_b} = \mathbb{P}(A_{i_a} \cap B_{i_b})$. Совместная энтропия опытов $\mathcal{A}$ и $\mathcal{B}$ определяется как:

$$\mathrm{H}_m(\mathcal{A}, \mathcal{B}) = -\sum_{i_a=1}^{n_a} \sum_{i_b=1}^{n_b} \mathbb{P}(A_{i_a}, B_{i_b}) \cdot \mathcal{I}_m(A_{i_a}, B_{i_b}) = -\sum_{i_a=1}^{n_a} \sum_{i_b=1}^{n_b} p_{i_a i_b} \log_m p_{i_a i_b}.$$

Мы можем думать о совместной энтропии, как об энтропии опыта, состоящего в одновременном проведении опытов $\mathcal{A}$ и $\mathcal{B}$. Формально это можно выразить следующим образом.

Определение 1.3.8 (Произведение двух опытов)**.** Пусть имеются два опыта:

$$\mathcal{A} = \{A_{i_a}\}_{i=1}^{n_a}, \quad \mathcal{B} = \{B_{i_b}\}_{i_b=1}^{n_b},$$

Их произведением называется опыт:

$$\mathcal{A} \wedge \mathcal{B} = \{A_{i_a} \cap B_{i_b} \mid \mathbb{P}(A_{i_a} \cap B_{i_b}) > 0\}_{i_a=1,\ldots,n_a}^{i_b=1,\ldots,n_b}.$$

Тогда получим что $\mathrm{H}(\mathcal{A}, \mathcal{B}) = \mathrm{H}(\mathcal{A} \wedge \mathcal{B})$. Естественным образом можно теперь ввести совместную энтропию нескольких опытов:

$$\mathrm{H}(\mathcal{A}_1, \ldots, \mathcal{A}_r) = \mathrm{H}(\mathcal{A}_1 \wedge \ldots \wedge \mathcal{A}_r).$$

Пример (Случайная монета, продолжение - 1)**.** Вернемся к модели, где выбор между настоящей и фальшивой монетой делается наугад. Два опыта: первый состоит в наблюдении того, какая была вытащена монета: $\mathcal{B} = \{\mathrm{H}, \Phi\}$. Второй состоит в наблюдении первого броска монеты и также имеет два результата, $\mathcal{A}_1 = \{O_1, P_1\}$. Их произведение при этом будет состоять из трёх событий:

$$\mathcal{A}_1 \wedge \mathcal{B} = \{\mathrm{H} \cap O_1, \Phi \cap P_1, \mathrm{H} \cap P_1\}$$

Поскольку при вытаскивании фальшивой монеты, орёл выпасть не может. Совместная энтропия при этом равна:

$$\mathrm{H}(\mathcal{A}_1, \mathcal{B}) = -\frac{1}{4}\log_2\frac{1}{4} - \frac{1}{4}\log_2\frac{1}{4} - \frac{1}{2}\log_2\frac{1}{2} = 1.5 \text{ бит}$$

Предложение 1.3.9 (Правило цепочки)**.** *Для двух случайных опытов $\mathcal{A}$ и $\mathcal{B}$ выполняется соотношение*

$$\mathrm{H}_m(\mathcal{A}, \mathcal{B}) = \mathrm{H}_m(\mathcal{A}) + \mathrm{H}(\mathcal{B} \mid \mathcal{A}) = \mathrm{H}_m(\mathcal{B}) + \mathrm{H}_m(\mathcal{A} \mid \mathcal{B}).$$

Доказательство. Не умаляя общности $m = 2$. По определению совместной энтропии:

$$\mathrm{H}(\mathcal{A}, \mathcal{B}) = -\sum_{i_a, i_b} p_{i_a i_b} \log p_{i_a i_b} = -\sum_{i_a, i_b} p_{i_a i_b} \log\big(p_{i_a} p_{i_b|i_a}\big) = -\sum_{i_a} p_{i_a} \log p_{i_a} - \sum_{i_a} p_i \sum_{i_b} p_{i_b|i_a} \log p_{i_b|i_a} = \mathrm{H}(\mathcal{A}) + \mathrm{H}(\mathcal{B} \mid \mathcal{A}).$$

Симметрично, меняя местами $\mathcal{A}$ и $\mathcal{B}$, получаем второе равенство. □

Пример (Случайная монета, продолжение - 2)**.** Можем убедиться, рассматривая модель, где выбор между настоящей и фальшивой монетой делается наугад. Как и ранее, рассматриваем два опыта: первый состоит в наблюдении того, какая была вытащена монета: $\mathcal{B} = \{\mathrm{H}, \Phi\}$. Второй состоит в наблюдении первого броска монеты и также имеет два результата, $\mathcal{A}_1 = \{O_1, P_1\}$.

По примеру ранее $\mathrm{H}(\mathcal{A}_1, \mathcal{B}) = 1.5$ бит. Энтропия $\mathrm{H}(\mathcal{B}) = 1$ бит. Посчитаем:

$$\mathrm{H}(\mathcal{A}_1 \mid \mathcal{B}) = -\mathbb{P}(\mathrm{H}) \cdot \underbrace{\big[\mathbb{P}(O_1 \mid \mathrm{H}) \log \mathbb{P}(O_1 \mid \mathrm{H}) + \mathbb{P}(P_1 \mid \mathrm{H}) \log \mathbb{P}(P_1 \mid \mathrm{H})\big]}_{1 \text{ бит}} - \mathbb{P}(\Phi) \cdot \underbrace{\mathbb{P}(P_1 \mid \Phi) \log \mathbb{P}(P_1 \mid \Phi)}_{0 \text{ бит}} = \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 0 = 0.5 \text{ бит}$$

Все вычисления сошлись.

Следствие 1.3.10. *Для любых двух опытов:*

$$\max\{\mathrm{H}(\mathcal{A}), \mathrm{H}(\mathcal{B})\} \le \mathrm{H}(\mathcal{A}, \mathcal{B}) \le \mathrm{H}(\mathcal{A}) + \mathrm{H}(\mathcal{B})$$

Причем

- *Равенство* $\mathrm{H}(\mathcal{A}) = \mathrm{H}(\mathcal{A}, \mathcal{B})$ *достигается тогда и только тогда, когда опыт $\mathcal{B}$ определяется опытом $\mathcal{A}$.*
- *Равенство* $\mathrm{H}(\mathcal{A}, \mathcal{B}) = \mathrm{H}(\mathcal{A}) + \mathrm{H}(\mathcal{B})$ *достигается тогда и только тогда, когда опыты $\mathcal{A}$ и $\mathcal{B}$ независимы.*

Доказательство. Запишем правило цепочки (предложение 1.3.9) и применим к нему с двух сторон оценки на условную энтропию (предложение 1.3.3)

$$\mathrm{H}(\mathcal{A}, \mathcal{B}) = \mathrm{H}(\mathcal{A}) + \mathrm{H}(\mathcal{B} \mid \mathcal{A}) \ge \mathrm{H}(\mathcal{A})$$
$$\mathrm{H}(\mathcal{A}, \mathcal{B}) = \mathrm{H}(\mathcal{A}) + \mathrm{H}(\mathcal{B} \mid \mathcal{A}) \le \mathrm{H}(\mathcal{A}) + \mathrm{H}(\mathcal{B})$$

Случаи равенства разбираются исходя из случаев равенства оценок в предложении 1.3.3. □

О значениях совместной энтропии

Теорема 1.3.11 (О значениях совместной энтропии)**.** *Для любых опытов $\mathcal{A}_1, \ldots, \mathcal{A}_r$:*

$$\max_{j=1,\ldots,r} \mathrm{H}_m(\mathcal{A}_j) \leq \mathrm{H}_m(\mathcal{A}_1, \ldots \mathcal{A}_r) \leq \sum_{j=1}^{r} \mathrm{H}_m(\mathcal{A}_j)$$

Причем

- *Равенство $\mathrm{H}_m(\mathcal{A}_1, \ldots \mathcal{A}_r) = \max \mathrm{H}_m(\mathcal{A}_j)$ достигается тогда и только тогда, когда один из опытов $\mathcal{A}_k$ определяет любой другой опыт $\mathcal{A}_j, j \neq k$.*
- *Равенство $\mathrm{H}_m(\mathcal{A}_1, \ldots \mathcal{A}_r) = \sum \mathrm{H}_m(\mathcal{A}_j)$ достигается тогда и только тогда, когда опыты $\mathcal{A}_1, \ldots, \mathcal{A}_r$ независимы в совокупности.*

Доказательство. Не умаляя общности $m = 2$. Индукцией по r. Базовый случай $r = 2$ уже доказан в следствии 1.3.10. Начнем с самих неравенств при $r \geq 3$. Имеем:

$$\mathrm{H}(\mathcal{A}_1, \ldots \mathcal{A}_r) = \mathrm{H}(\mathcal{A}_1, \mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r) \geq \max\{\mathrm{H}(\mathcal{A}_1), \mathrm{H}(\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r)\} = \max\{\mathrm{H}(\mathcal{A}_1), \mathrm{H}(\mathcal{A}_2, \ldots, \mathcal{A}_r)\} \underset{*}{\geq} \max_{j=1,\ldots,r} \mathrm{H}(\mathcal{A}_j)$$

$$\mathrm{H}(\mathcal{A}_1, \ldots \mathcal{A}_r) = \mathrm{H}(\mathcal{A}_1, \mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r) \leq \mathrm{H}(\mathcal{A}_1) + \mathrm{H}(\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r) = \mathrm{H}(\mathcal{A}_1) + \mathrm{H}(\mathcal{A}_2, \ldots, \mathcal{A}_r) \underset{*}{\leq} \sum_{j=1}^{r} \mathrm{H}(\mathcal{A}_j),$$

где переходы $*$ сделаны по предположению индукции. Разберем случай равенства.

Равенство максимуму. Не умаляя общности пусть

$$\mathrm{H}(\mathcal{A}_1, \ldots \mathcal{A}_r) = \mathrm{H}(\mathcal{A}_1)$$

Тогда, так как $\mathrm{H}(\mathcal{A}_1, \ldots \mathcal{A}_r) = \mathrm{H}(\mathcal{A}_1, \mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r)$, получаем что опыт $\mathcal{A}_1$ полностью определяет опыт $\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r$. Формально это означает, что для любого набора событий $A_1 \in \mathcal{A}_1, \ldots, A_r \in \mathcal{A}_r$:

$$\mathbb{P}(A_2 \cap \ldots \cap A_r \mid A_1) \in \{0, 1\}$$

Покажем что $\mathbb{P}(A_2 \mid A_1) \in \{0, 1\}$: распишем:

$$\mathbb{P}(A_2 \mid A_1) = \sum_{A_3 \in \mathcal{A}_3} \cdots \sum_{A_r \in \mathcal{A}_r} \mathbb{P}(A_2 \cap \ldots \cap A_r \mid A_1)$$

Каждое слагаемое в правой части это либо 0, либо 1. С другой стороны, поскольку условная вероятность лежит в отрезке $[0; 1]$, получаем что вся сумма принимает значение или 0, или 1, что и требовалось доказать. Аналогично получаем что $\mathbb{P}(A_j \mid A_1) \in \{0, 1\}$ при $j \neq 1$. В другую сторону случай равенства следует из того что, если опыт $\mathcal{A}_1$ определяет опыты $\mathcal{A}_2$ и $\mathcal{A}_3$, то определяет и опыт $\mathcal{A}_2 \wedge \mathcal{A}_3$, поскольку пересечение событий вероятностей 0 или 1, само есть событие вероятности 0 или 1.

Равенство сумме. Имеем:

$$\mathrm{H}(\mathcal{A}_1, \ldots, \mathcal{A}_r) = \sum_{j=1}^{r} \mathrm{H}(\mathcal{A}_j)$$

Тогда, так как $\mathrm{H}(\mathcal{A}_1, \ldots \mathcal{A}_r) = \mathrm{H}(\mathcal{A}_1, \mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r)$ имеем:

1. Опыты $\mathcal{A}_1$ и $\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r$ независимы;
2. $\mathrm{H}(\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r) = \mathrm{H}(\mathcal{A}_2) + \ldots + \mathrm{H}(\mathcal{A}_r)$

Хотим проверить что для любого поднабора $\mathcal{A}_{j_1}, \ldots, \mathcal{A}_{j_k}$ и любых событий $A_1 \in \mathcal{A}_{j_1}, \ldots, \mathcal{A}_{j_k}$ выполнено равенство

$$\mathbb{P}(A_1 \cap \ldots \cap A_k) = \mathbb{P}(A_1) \cdot \ldots \cdot \mathbb{P}(A_k) \tag{1.4}$$

Применяя индукционное предположение к пункту 2, получаем что опыты $\mathcal{A}_2, \ldots, \mathcal{A}_r$ независимы в совокупности. Таким образом, равенство (1.4) выполнено, когда среди набора $\mathcal{A}_{j_1}, \ldots, \mathcal{A}_{j_k}$ нет опыта $\mathcal{A}_1$. Тогда, чтобы доказать независимость в совокупности опытов $\mathcal{A}_1, \ldots, \mathcal{A}_r$ нужно показать равенство (1.4) для поднаборов $\mathcal{A}_{j_1}, \ldots, \mathcal{A}_{j_k}$ с $j_1 = 1$ и произвольных $A_1 \in \mathcal{A}_{j_1}, \ldots, A_k \in \mathcal{A}_{j_k}$.

Обозначим за $t_1, \ldots, t_{r-k}$ индексы не вошедшие в набор $j_1, \ldots, j_k$, т.е. $\{t_1, \ldots, t_{r-k}\} = \{1, \ldots, r\} \setminus \{j_1, \ldots, j_k\}$; Имеем по пункту 1:

$$\mathbb{P}(A_1 \cap \ldots \cap A_k) = \sum_{A_{k+1} \in \mathcal{A}_{t_1}} \cdots \sum_{A_r \in \mathcal{A}_{t_{r-k}}} \underbrace{\mathbb{P}(A_1 \cap \ldots A_k \cap A_{k+1} \ldots A_r)}_{\in \mathcal{A}_1 \wedge \ldots \wedge \mathcal{A}_r} =$$

$$= \sum_{A_{k+1} \in \mathcal{A}_{t_1}} \cdots \sum_{A_r \in \mathcal{A}_{t_{r-k}}} \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 \cap \ldots A_k \cap A_{k+1} \ldots A_r) = \mathbb{P}(A_1) \cdot \sum_{A_{k+1} \in \mathcal{A}_{t_1}} \cdots \sum_{A_r \in \mathcal{A}_{t_{r-k}}} \mathbb{P}(A_2 \cap \ldots A_k \cap A_{k+1} \ldots A_r) =$$

$$= \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 \cap \ldots A_k) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2) \cdot \ldots \cdot \mathbb{P}(A_k)$$

Что и требовалось доказать. В обратную сторону случай равенства напрямую следует из 1.3.10. □

1.3.4. Вариации на тему правила цепочки

Заметим что из предложения 1.3.9 немедленно следует более общее правило цепочки:

Следствие 1.3.12. *Для любых опытов $\mathcal{A}_1, \dots, \mathcal{A}_r$:*

$$\mathrm{H}_m(\mathcal{A}_1, \dots, \mathcal{A}_r) = \mathrm{H}_m(\mathcal{A}_1) + \sum_{i=2}^{r} \mathrm{H}_m(\mathcal{A}_i \mid \mathcal{A}_{i-1}, \dots, \mathcal{A}_1)$$

Замечание. Далее для краткости, во всех конструкциях, где фигурирует взятие условия $\mid$ принимаем следующее соглашение. Если условие составное и его части пишутся через запятую, то при наличии знака многоточия для перечисления событий по некоторому множеству индексов, то

1. если результирующее множество условий пусто, понимаем это как отсутствие условия. Например, при $i > j$ под выражением $\mathrm{H}(\mathcal{B} \mid \mathcal{A}_i, \mathcal{A}_{i+1}, \dots, \mathcal{A}_j)$ понимается $\mathrm{H}(\mathcal{B})$;
2. если результирующее множество условий записанных через многоточие пусто, но есть ещё какие-то другие условия, понимаем это как взятие условия по всем, не входящим в запись через многоточие, условиям. Например, при $k = 1$ под выражением $\mathbb{P}(A_k \mid A_{k-1}, \mathcal{A}_{k-2}, \dots, A_1, B)$ понимается $\mathbb{P}(A_1 \mid B)$;

В такой нотации правило цепочки для вероятностей $\mathbb{P}(E_1, \dots, E_r) = \mathbb{P}(E_1) \cdot \mathbb{P}(E_2 \mid E_1) \cdots \mathbb{P}(E_r \mid E_{r-1}, \dots, E_1)$ например будет записываться как

$$\mathbb{P}(E_1, \dots, E_r) = \prod_{i=1}^{r} \mathbb{P}(E_i \mid E_1, \dots, E_{i-1}),$$

а условие следствия 1.3.12 может быть записано как:

$$\mathrm{H}_m(\mathcal{A}_1, \dots, \mathcal{A}_r) = \sum_{i=1}^{r} \mathrm{H}_m(\mathcal{A}_i \mid \mathcal{A}_{i-1}, \dots, \mathcal{A}_1)$$

Доказательство следствия 1.3.12. Не умаляя общности $m = 2$. По индукции. Базовый случай рассмотрен в 1.3.9. Докажем индукционный переход $r \to r+1$. Рассмотрим:

$$\mathrm{H}(\mathcal{A}_1, \dots, \mathcal{A}_r, \mathcal{A}_{r+1}) \overset{*_2}{=} \mathrm{H}(\mathcal{A}_1, \dots, \mathcal{A}_r) + \mathrm{H}(\mathcal{A}_{r+1} \mid \mathcal{A}_1, \dots, \mathcal{A}_r) =$$
$$\overset{*_r}{=} \sum_{i=1}^{r} \mathrm{H}(\mathcal{A}_i \mid \mathcal{A}_{i-1}, \dots, \mathcal{A}_1) + \mathrm{H}(\mathcal{A}_{n+1} \mid \mathcal{A}_1, \dots, \mathcal{A}_r) = \sum_{i=1}^{r+1} \mathrm{H}(\mathcal{A}_i \mid \mathcal{A}_{i-1}, \dots, \mathcal{A}_1)$$

где $*$ означает переход сделанный по предположению индукции. □

Аналогично предложению 1.3.9 и следствию 1.3.12 можно сформулировать их «условные» аналоги.

Предложение 1.3.13. *Для любых трёх опытов $\mathcal{A}, \mathcal{B}, \mathcal{C}$ выполнено:*

$$\mathrm{H}_m(\mathcal{A}, \mathcal{B} \mid \mathcal{C}) = \mathrm{H}_m(\mathcal{A} \mid \mathcal{C}) + \mathrm{H}_m(\mathcal{B} \mid \mathcal{A}, \mathcal{C})$$

Доказательство. Не умаляя общности $m = 2$. Пусть $\mathcal{A} = \{A_1, \dots, A_{n_a}\}, \mathcal{B} = \{B_1, \dots, B_{n_b}\}, \mathcal{C} = \{C_1, \dots, C_{n_c}\}$. Запишем по определению

$$\mathrm{H}(\mathcal{A}, \mathcal{B} \mid \mathcal{C}) = \sum_{i_c=1}^{n_c} \mathbb{P}(C_{i_c}) \sum_{i_a=1}^{n_a} \sum_{i_b=1}^{n_b} \mathbb{P}(A_{i_a}, B_{i_b} \mid C_{i_c}) \log \mathbb{P}(A_{i_a}, B_{i_b} \mid C_{i_c}).$$

Обозначим $\mathbb{P}_{i_c}(\cdot) = \mathbb{P}(\cdot \mid C_{i_c})$. Тогда:

$$\mathrm{H}(\mathcal{A}, \mathcal{B} \mid \mathcal{C}) = -\sum_{i_c=1}^{n_c} \mathbb{P}(C_{i_c}) \overbrace{\sum_{i_a=1}^{n_a} \sum_{i_b=1}^{n_b} \mathbb{P}_{i_c}(A_{i_a}, B_{i_b}) \log \mathbb{P}_{i_c}(A_{i_a}, B_{i_b})}^{\mathrm{H}(\mathcal{A},\mathcal{B}) \text{ относительно } \mathbb{P}_{i_c}} = [\text{Правило цепочки для } \mathrm{H}(\mathcal{A}, \mathcal{B}) \text{ относительно } \mathbb{P}_{i_c}] =$$
$$= -\sum_{i_c=1}^{n_c} \mathbb{P}(C_{i_c}) \cdot \left[\sum_{i_a=1}^{n_a} \mathbb{P}_{i_c}(A_{i_a}) \log \mathbb{P}_{i_c}(A_{i_a}) + \sum_{i_a=1}^{n_a} \mathbb{P}_{i_c}(A_{i_a}) \sum_{i_b=1}^{n_b} \mathbb{P}_{i_c}(B_{i_b} \mid A_{i_a}) \log \mathbb{P}(B_{i_b} \mid A_{i_a}) \right] =$$
$$= -\sum_{i_c=1}^{n_c} \mathbb{P}(C_{i_c}) \sum_{i_a=1}^{n_a} \mathbb{P}_{i_c}(A_{i_a}) \log \mathbb{P}_{i_c}(A_{i_a}) - \sum_{i_c=1}^{n_c} \sum_{i_a=1}^{n_a} \mathbb{P}(C_{i_c}) \mathbb{P}_{i_c}(A_{i_a}) \sum_{i_b=1}^{n_b} \mathbb{P}_{i_c}(B_{i_b} \mid A_{i_a}) \log \mathbb{P}_{i_c}(B_{i_b} \mid A_{i_a})$$

Заметим что $\mathbb{P}(C_{i_c}) \mathbb{P}_{i_c}(A_{i_a}) = \mathbb{P}(C_{i_c}) \mathbb{P}(A_{i_a} \mid C_{i_c}) = \mathbb{P}(A_{i_a}, C_{i_c})$ и что $\mathbb{P}_{i_c}(B_{i_b} \mid A_{i_a}) = \mathbb{P}(B_{i_b} \mid A_{i_a}, C_{i_c})$:

$$\mathbb{P}_{i_c}(B_{i_b} \mid A_{i_a}) = \frac{\mathbb{P}_{i_c}(B_{i_b} \cap A_{i_a})}{\mathbb{P}_{i_c}(A_{i_a})} = \frac{\mathbb{P}(B_{i_b} \cap A_{i_a} \mid C_{i_c})}{\mathbb{P}(A_{i_a} \mid C_{i_c})} = \frac{\mathbb{P}(B_{i_b} \cap A_{i_a} \cap C_{i_c})}{\mathbb{P}(A_{i_a} \cap C_{i_c})} = \mathbb{P}(B_{i_b} \mid A_{i_a}, C_{i_c})$$

Получили что:

$$\mathrm{H}(\mathcal{A},\mathcal{B}\mid\mathcal{C}) = \underbrace{-\sum_{i_c=1}^{n_c}\mathbb{P}(C_{i_c})\sum_{i_a=1}^{n_a}\mathbb{P}(A_{i_a}\mid C_{i_c})\log\mathbb{P}(A_{i_a}\mid C_{i_c})}_{\mathrm{H}(\mathcal{A}|\mathcal{C})} \underbrace{-\sum_{i_c=1}^{n_c}\sum_{i_a=1}^{n_a}\mathbb{P}(A_{i_a},C_{i_c})\sum_{i_b=1}^{n_b}\mathbb{P}(B_{i_b}\mid A_{i_a},C_{i_c})\log\mathbb{P}(B_{i_b}\mid A_{i_a},C_{i_c})}_{\mathrm{H}(\mathcal{B}|\mathcal{A},\mathcal{C})}$$

Что и требовалось доказать. □

Следствие 1.3.14. *Для любых опытов $\mathcal{A}_1,\ldots,\mathcal{A}_r$ и опыта $\mathcal{B}$:*

$$\mathrm{H}_m(\mathcal{A}_1,\ldots,\mathcal{A}_r\mid\mathcal{B}) = \sum_{i=1}^{r}\mathrm{H}_m(\mathcal{A}_i\mid\mathcal{B},\mathcal{A}_{i-1},\ldots,\mathcal{A}_1)$$

Доказательство. Не умаляя общности $m=2$. Доказательство по индукции. Базовый случай $r=2$ следует из предложения 1.3.13. Сделаем индукционный переход:

$$\mathrm{H}(\mathcal{A}_1,\ldots,\mathcal{A}_r,\mathcal{A}_{r+1}\mid\mathcal{B}) \overset{*_2}{=} \mathrm{H}(\mathcal{A}_1,\ldots,\mathcal{A}_r\mid\mathcal{B}) + \mathrm{H}(\mathcal{A}_{r+1}\mid\mathcal{B},\mathcal{A}_1,\ldots,\mathcal{A}_n) =$$
$$\overset{*_r}{=} \sum_{i=1}^{r}\mathrm{H}_m(\mathcal{A}_i\mid\mathcal{B},\mathcal{A}_{i-1},\ldots,\mathcal{A}_1) + \mathrm{H}(\mathcal{A}_{r+1}\mid\mathcal{B},\mathcal{A}_1,\ldots,\mathcal{A}_r) = \sum_{i=1}^{r+1}\mathrm{H}_m(\mathcal{A}_i\mid\mathcal{B},\mathcal{A}_{i-1},\ldots,\mathcal{A}_1)$$

где $*$ означает переход сделанный по предположению индукции. □

Приложение. О независимых опытах, σ-алгебрах и энтропии

Доказательство теоремы 1.3.11 выглядит довольно хитрым и возникает соблазн как-то его упростить. Можно; но для этого придется сделать язык чуть более абстрактным и доказать пару предварительных результатов.

Замечание. Это приложение — скорее черновик того, как можно развивать мысль. Многие переходы намерено расписаны не очень подробно или даже туманно, дабы дать читателю некоторую творческую свободу. Можно расценивать это приложение как руководство по тому, как не стоит записывать доказательства.

Для начала, дадим теоретико-множественную трактовку тому, что один опыт определяет другой.

Определение (Эквивалентность опытов $\bmod 0$)**.** *Опыты $\mathcal{A}$ и $\mathcal{B}$ называются равными $\bmod 0$, если для любого результата $A \in \mathcal{A}$ существует результат $B \in \mathcal{B}$ такой, что*

$$\mathbb{P}(A \triangle B) = 0,$$

где $A \triangle B$ — симметрическая разность множеств. Записывается как $\mathcal{A} = \mathcal{B} \pmod 0$.

Замечание. $\cdot = \cdot \pmod 0$ это отношение эквивалентности.

Предложение. *Опыт $\mathcal{B}$ определяется опытом $\mathcal{A}$ тогда и только тогда, когда:*

$$\mathcal{A} = \mathcal{A} \wedge \mathcal{B} \pmod 0.$$

Доказательство. Пусть опыт $\mathcal{B}$ определяется опытом $\mathcal{A}$. Так как $\mathcal{B}$ определяется $\mathcal{A}$, для любого $A_{i_a} \in \mathcal{A}$ существует единственное $B_{i_b} \in \mathcal{B}$ такое что

$$\mathbb{P}(B_{i_b} \mid A_{i_a}) = 1$$

Иначе говоря $\mathbb{P}(B_{i_b} \cap A_{i_a}) = \mathbb{P}(A_{i_a})$. Значит, по аддитивности вероятности, $\mathbb{P}((A_{i_a} \cap B_{i_b}) \triangle A_{i_a}) = 0$. Отсюда прямым образом следует $\mathcal{A} = \mathcal{A} \wedge \mathcal{B} \pmod 0$.

Теперь обратно. Если $\mathcal{A} = \mathcal{A} \wedge \mathcal{B} \pmod 0$, то любое событие $B \in \mathcal{B}$ представимо, с точностью до множества меры 0, как объединение нескольких множеств $A_1, \dots A_k \in \mathcal{A}$, а значит все условные вероятности вырождены. □

Замечание. Интуиция тут может быть следующая. Каждый опыт задает некоторое разбиение пространства элементарных исходов Ω. Опыт $\mathcal{A}$ определяет $\mathcal{B}$, если опыт $\mathcal{A}$ как разбиение Ω является измельчением разбиения $\mathcal{B}$ (с точностью до множеств меры 0).

Однако как подсказывает заголовок при как подсказывает заголовок приложения, речь в какой-то момент должна зайти о σ-алгебрах. Действительно, формулировки о том что две (или больше) системы событий независимы или определяют друг друга в некотором смысле выглядят кустарно. Оказывается, если вместо полной системы событий $\mathcal{A}$ рассматривать порождённую ей σ-алгебру $\sigma(\mathcal{A})$ мы придем к более естественным формулировкам.

Определение. *Для двух σ-алгебр $\mathcal{F} \subset \mathcal{H}$ и $\mathcal{G} \subset \mathcal{H}$ на одном вероятностном пространстве $(\Omega, \mathcal{H}, \mathbb{P})$, их совместная σ-алгебра есть*

$$\mathcal{F} \vee \mathcal{G} =: \sigma(\mathcal{F} \cup \mathcal{G}),$$

то есть наименьшая σ-алгебра, содержащая $\mathcal{F}$ и $\mathcal{G}$.

Предложение. *Пусть $\mathcal{A}, \mathcal{B}$ — полные системы событий. Тогда*

$$\sigma(\mathcal{A}) \vee \sigma(\mathcal{B}) = \sigma(\mathcal{A} \wedge \mathcal{B}),$$

Доказательство. С одной стороны, каждый элемент $A \cap B$ принадлежит $\sigma(\mathcal{A})$ и $\sigma(\mathcal{B})$, следовательно,

$$\sigma(\mathcal{A} \wedge \mathcal{B}) \subseteq \sigma(\mathcal{A}) \vee \sigma(\mathcal{B}).$$

С другой стороны, любые события из $\mathcal{A}$ и $\mathcal{B}$ могут быть получены как объединения пересечений $A \cap B$. Поэтому есть включение $\sigma(\mathcal{A}) \cup \sigma(\mathcal{B}) \subseteq \sigma(\mathcal{A} \wedge \mathcal{B})$, а значит и их порождённая σ-алгебра $\sigma(\mathcal{A}) \vee \sigma(\mathcal{B})$ содержится в $\sigma(\mathcal{A} \wedge \mathcal{B})$. Получаем равенство. □

Для σ-алгебр аналогично полным системам событий можно ввести понятие равенство $\bmod 0$ и включения $\bmod 0$ (последнее означает, что каждый элемент из более грубой σ-алгебры с точностью до множества вероятности 0 содержится в более тонкой σ-алгебре).

Оказывается что верно следующее:

Предложение. *Опыт $\mathcal{B}$ определяется опытом $\mathcal{A}$ тогда и только тогда, когда $\sigma(\mathcal{B}) \subseteq \sigma(\mathcal{A}) \pmod 0$.*

Доказательство. Следует из ранее доказанного. □

Теперь надо разобраться с независимостью опытов. Для σ-алгебр понятие независимости вводится следующим образом:

Определение (Независимость сигма-алгебр)**.** *Сигма-алгебры $\mathcal{F}_1 \subset \mathcal{H}, \ldots, \mathcal{F}_r \subset \mathcal{H}$ на одном вероятностном пространстве $(\Omega, \mathcal{H}, \mathbb{P})$ называются независимыми в совокупности, если для всех $F_1 \in \mathcal{F}_1, \ldots, F_r \in \mathcal{F}_r$:*

$$\mathbb{P}(F_1 \cap \ldots \cap F_r) = \mathbb{P}(F_1) \ldots \mathbb{P}(F_r).$$

Замечание. Полагая некоторые из F_i равными Ω, получаем что события $F_1, \ldots, F_r$ будут независимы в совокупности.

Лемма. *Пусть E — событие, $\mathcal{A}$ — некоторый опыт, и E независимо от любого $A \in \mathcal{A}$. Тогда E независимо от любого события $C \in \sigma(\mathcal{A})$.*

Доказательство. Каждое $C \in \sigma(\mathcal{A})$ представимо как объединение некоторых множеств $A_{j_1}, \ldots, A_{j_k} \in \mathcal{A}$. Распишем

$$\mathbb{P}(E \cap C) = \mathbb{P}(E \cap [A_{j_1} \cup \ldots A_{j_k}]) = \sum_{i=1}^{k} \mathbb{P}(E \cap A_{j_i}) = \mathbb{P}(E) \sum_{i=1}^{k} \mathbb{P}(A_{j_i}) = \mathbb{P}(E)\mathbb{P}(C)$$

□

Следствие. *Опыты $\mathcal{A}$ и $\mathcal{B}$ независимы тогда и только тогда, когда независимы $\sigma(\mathcal{A})$ и $\sigma(\mathcal{B})$.*

Доказательство. Из независимости σ-алгебр независимость опытов следует по определению. В другую сторону. Пусть теперь $A \in \sigma(\mathcal{A}), B \in \sigma(\mathcal{B})$. Поскольку опыты $\mathcal{A}$ и $\mathcal{B}$ независимы, событие $B \in \sigma(\mathcal{B})$ и событие $A' \in \mathcal{A}$ независимы для любого события A' в силу леммы выше. Тогда применяя лемму теперь уже к событию B получаем что B независимо с любым $A \in \sigma(\mathcal{A})$. □

Замечание. Обобщение на случай нескольких независимых в совокупности опытов доказывается mutatis mutandis.

Предложение. *Пусть $\mathcal{F}_1$, $\mathcal{F}_2$ — две независимые σ-алгебры на $(\Omega, \mathcal{H}, \mathbb{P})$, $\mathcal{G} \subset \mathcal{F}_1$. Тогда $\mathcal{G}$ и $\mathcal{F}_2$ независимы.*

Доказательство. Следует напрямую из определения. □

Упрощённое доказательство теоремы о совместной энтропии.

1. **Равенство с максимумом.** Предположим

$$\mathrm{H}(\mathcal{A}_1, \ldots, \mathcal{A}_r) = \mathrm{H}(\mathcal{A}_1).$$

По определению совместной энтропии

$$\mathrm{H}(\mathcal{A}_1, \ldots, \mathcal{A}_r) = \mathrm{H}\big(\mathcal{A}_1 \wedge (\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r)\big).$$

Следовательно,

$$\mathrm{H}(\mathcal{A}_1) = \mathrm{H}\big(\mathcal{A}_1 \wedge (\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r)\big),$$

а значит $\sigma(\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r) \subseteq \sigma(\mathcal{A}_1) \pmod 0$. Поскольку $\sigma(\mathcal{A}_j) \subseteq \sigma(\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r)$ для любого $j \geq 2$, получаем

$$\sigma(\mathcal{A}_j) \subseteq \sigma(\mathcal{A}_1) \pmod 0, \qquad j = 2, \ldots, r.$$

Это эквивалентно тому, что каждый опыт $\mathcal{A}_j$ определяется $\mathcal{A}_1$, что и требовалось.

2. **Равенство с суммой.** Предположим

$$\mathrm{H}(\mathcal{A}_1, \ldots, \mathcal{A}_r) = \sum_{j=1}^{r} \mathrm{H}(\mathcal{A}_j).$$

По уже доказанному случаю $r = 2$ получаем

$$\sigma(\mathcal{A}_1) \text{ независима от } \sigma(\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r),$$

а также

$$\mathrm{H}(\mathcal{A}_2 \wedge \ldots \wedge \mathcal{A}_r) = \sum_{j=2}^{r} \mathrm{H}(\mathcal{A}_j),$$

что по индукционному предположению означает независимость сигма-алгебр $\sigma(\mathcal{A}_2), \ldots, \sigma(\mathcal{A}_r)$ в совокупности. Теперь, используя независимость $\sigma(\mathcal{A}_1)$ от их объединения $\sigma(\mathcal{A}_2 \vee \ldots \vee \mathcal{A}_r)$ и факт $\sigma(\mathcal{A}_2 \vee \ldots \vee \mathcal{A}_r) = \sigma(\mathcal{A}_2) \wedge \ldots \wedge \sigma(\mathcal{A}_r)$, получаем независимость всех $\sigma(\mathcal{A}_j)$, $j = 1, \ldots, r$ (поскольку это подалгебры $\sigma(\mathcal{A}_2) \wedge \ldots \wedge \sigma(\mathcal{A}_r)$). Это эквивалентно независимости самих опытов $\mathcal{A}_1, \ldots, \mathcal{A}_r$.

1.4. Взаимная информация

Оглавление

1.4.1 Взаимная информация 22
1.4.2 Условная взаимная информация 23
1.4.3 Информация взаимодействия 25

1.4.1. Взаимная информация

Определение 1.4.1. Пусть $\mathcal{A}$ и $\mathcal{B}$ — два опыта. Взаимная информация $\mathcal{I}_m(\mathcal{A};\mathcal{B})$ между опытами $\mathcal{A}$ и $\mathcal{B}$ определяется как

$$\mathcal{I}_m(\mathcal{A};\mathcal{B}) = \mathrm{H}_m(\mathcal{A}) + \mathrm{H}_m(\mathcal{B}) - \mathrm{H}_m(\mathcal{A},\mathcal{B}).$$

Замечание. Эквивалентно, используя правило цепочки можно расписать взаимную информацию как:

$$\mathcal{I}_m(\mathcal{A};\mathcal{B}) = \mathrm{H}_m(\mathcal{A}) - \mathrm{H}_m(\mathcal{A}\mid\mathcal{B}) = \mathrm{H}_m(\mathcal{B}) - \mathrm{H}_m(\mathcal{B}\mid\mathcal{A}).$$

Графически это можно представлять в виде мнемоники изображенной на рис. 1.3.

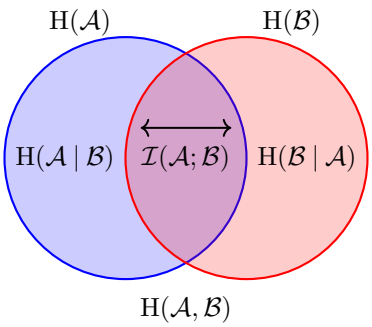

Рис. 1.3: *Представление взаимной информации через круги Эйлера*

Взаимную информацию можно мыслить как меру того, сколько знание результата одного опыта уменьшает энтропию другого опыта в среднем (поскольку $\mathrm{H}_m(\mathcal{B}\mid\mathcal{A})$ это усредненное по результатам опыта $\mathcal{A}$ значение энтропии опыта $\mathcal{B}$ при условии известного результата $\mathcal{A}$).

Предложение 1.4.2 (Свойства взаимной информации)**.** *Для любых двух опытов $\mathcal{A}$ и $\mathcal{B}$*

1. $\mathcal{I}_m(\mathcal{A};\mathcal{B}) = \mathcal{I}_m(\mathcal{B};\mathcal{A})$.
2. $0 \le \mathcal{I}_m(\mathcal{A};\mathcal{B}) \le \min\{\mathrm{H}_m(\mathcal{A}), \mathrm{H}_m(\mathcal{B})\}$, *причем:*
   - *равенство $\mathcal{I}_m(\mathcal{A};\mathcal{B}) = 0$ достигается тогда и только тогда, когда опыты $\mathcal{A}$ и $\mathcal{B}$ независимы;*
   - *равенство $\mathcal{I}_m(\mathcal{A};\mathcal{B}) = \mathrm{H}_m(\mathcal{A})$ достигается тогда и только тогда, когда опыт $\mathcal{B}$ определяет опыт $\mathcal{A}$.*

Доказательство. Не умаляя общности $m = 2$.

1. Симметричность очевидна из определения.

2. Неотрицательность. По определению $\mathcal{I}(\mathcal{A};\mathcal{B}) = \mathrm{H}(\mathcal{A}) - \mathrm{H}(\mathcal{A}\mid\mathcal{B})$. Из предложения 1.3.3 имеем $\mathrm{H}(\mathcal{A}\mid\mathcal{B}) \le \mathrm{H}(\mathcal{A})$, причем равенство достигается тогда и только тогда, когда опыты $\mathcal{A}$ и $\mathcal{B}$ независимы. Следовательно, $\mathcal{I}(\mathcal{A};\mathcal{B}) \ge 0$, и $\mathcal{I}(\mathcal{A};\mathcal{B}) = 0$ тогда и только тогда, когда $\mathcal{A}$ и $\mathcal{B}$ независимы.

3. Оценка минимумом из энтропий. Из правила цепочки $\mathcal{I}(\mathcal{A};\mathcal{B}) = \mathrm{H}(\mathcal{A}) - \mathrm{H}(\mathcal{A}\mid\mathcal{B}) \le \mathrm{H}(\mathcal{A})$, так как $\mathrm{H}(\mathcal{A}\mid\mathcal{B}) \ge 0$. Аналогично, $\mathcal{I}(\mathcal{A};\mathcal{B}) \le \mathrm{H}(\mathcal{B})$. Таким образом, $\mathcal{I}(\mathcal{A};\mathcal{B}) \le \min\{\mathrm{H}(\mathcal{A}), \mathrm{H}(\mathcal{B})\}$. Равенство $\mathcal{I}(\mathcal{A};\mathcal{B}) = \mathrm{H}(\mathcal{A})$ достигается тогда и только тогда, когда $\mathrm{H}(\mathcal{A}\mid\mathcal{B}) = 0$, что по предложению 1.3.3 эквивалентно тому, что опыт $\mathcal{B}$ определяет опыт $\mathcal{A}$.

□

Пример (Сумма двух четырехгранных костей)**.** Предположим что бросается две четырехгранные кости. Рассмотрим два опыта: $\mathcal{A}$ — наблюдается значение на первой кости (состоит из событий $\{$*Выпало 1*, …, *Выпало 4*$\}$), $\mathcal{B}$ — наблюдается сумма выпавших значений ($\mathcal{B} = \{\{S = 2\}, \dots, \{S = 8\}\}$). В предположении, что кости честные, имеем $\mathrm{H}(\mathcal{A}) = \log_2 4 = 2$ бита (энтропия опыта, результаты которого равновероятны). Условная энтропия $\mathrm{H}(\mathcal{B}\mid\mathcal{A})$ также равна двум битам: при

фиксированном значении на первой грани, сумма равномерно распределена на 4 значениях, поэтому $\mathrm{H}(\mathcal{B} \mid \mathcal{A}) = 2$ бита. Вычислим $\mathrm{H}(\mathcal{B})$ непосредственно. Распределение суммы S:

$$\mathbb{P}(S=2) = \frac{1}{16},\ \mathbb{P}(S=3) = \frac{2}{16},\ \mathbb{P}(S=4) = \frac{3}{16},\ \mathbb{P}(S=5) = \frac{4}{16},\ \mathbb{P}(S=6) = \frac{3}{16},\ \mathbb{P}(S=7) = \frac{2}{16},\ \mathbb{P}(S=8) = \frac{1}{16}.$$

Значит

$$\mathrm{H}(\mathcal{B}) = -\sum_{k=2}^{8} \mathbb{P}(S=k)\log\mathbb{P}(S=k) = -\frac{2\cdot 1}{16}\log_2\frac{1}{16} - \frac{2\cdot 2}{16}\log_2\frac{2}{16} - \frac{2\cdot 3}{16}\log_2\frac{3}{16} - \frac{1\cdot 4}{16}\log_2\frac{4}{16} \approx 2.656 \text{ бита.}$$

Таким образом,

$$\mathcal{I}(\mathcal{A};\mathcal{B}) = \mathrm{H}(\mathcal{B}) - \mathrm{H}(\mathcal{B} \mid \mathcal{A}) = 2.656 - 2 = 0.656 \text{ бита.}$$

Заметим, что $\mathcal{I}(\mathcal{A};\mathcal{B}) < \mathrm{H}(\mathcal{A})$, так как знание суммы не полностью определяет значение первого кубика.

1.4.2. Условная взаимная информация

Нотация. $\mathcal{I}(\mathcal{A}_1,\ldots,\mathcal{A}_r;\mathcal{B}_1,\ldots,\mathcal{B}_s) = \mathcal{I}(\mathcal{A}_1\wedge\ldots\wedge\mathcal{A}_r;\mathcal{B}_1\wedge\ldots\wedge\mathcal{B}_s)$

Определение 1.4.3. Условная взаимная информация между опытами $\mathcal{A}$ и $\mathcal{B}$ при условии опыта $\mathcal{C}$ определяется как

$$\mathcal{I}_m(\mathcal{A};\mathcal{B} \mid \mathcal{C}) = \mathrm{H}_m(\mathcal{A} \mid \mathcal{C}) + \mathrm{H}_m(\mathcal{B} \mid \mathcal{C}) - \mathrm{H}_m(\mathcal{A},\mathcal{B} \mid \mathcal{C}).$$

Замечание. Из определения и правила цепочки для условной энтропии получаем эквивалентные формы:

$$\mathcal{I}_m(\mathcal{A};\mathcal{B} \mid \mathcal{C}) = \mathrm{H}_m(\mathcal{A} \mid \mathcal{C}) - \mathrm{H}_m(\mathcal{A} \mid \mathcal{B},\mathcal{C}) = \mathrm{H}_m(\mathcal{B} \mid \mathcal{C}) - \mathrm{H}_m(\mathcal{B} \mid \mathcal{A},\mathcal{C}).$$

Предложение 1.4.4 (Свойства условной взаимной информации)**.** *Для любых трёх опытов $\mathcal{A},\mathcal{B},\mathcal{C}$:*
- $\mathcal{I}_m(\mathcal{A};\mathcal{B} \mid \mathcal{C}) \geq 0$.
- $\mathcal{I}_m(\mathcal{A};\mathcal{B} \mid \mathcal{C}) = \mathcal{I}_m(\mathcal{B};\mathcal{A} \mid \mathcal{C})$.

Доказательство. Не умаляя общности $m = 2$. Симметричность очевидна из определения. Для доказательства неотрицательности запишем:

$$\mathcal{I}(\mathcal{A};\mathcal{B} \mid \mathcal{C}) = \mathrm{H}(\mathcal{A} \mid \mathcal{C}) - \mathrm{H}(\mathcal{A} \mid \mathcal{B},\mathcal{C}).$$

Покажем, что $\mathrm{H}(\mathcal{A} \mid \mathcal{B},\mathcal{C}) \leq \mathrm{H}(\mathcal{A} \mid \mathcal{C})$. Пусть $\mathcal{A} = \{A_1,\ldots,A_{n_a}\}, \mathcal{B} = \{B_1,\ldots,B_{n_b}\}, \mathcal{C} = \{C_1,\ldots,C_{n_c}\}$. Распишем разность используя то что $\mathbb{P}(B_{i_b},C_{i_c}) = \mathbb{P}(C_{i_c})\cdot\mathbb{P}(B_{i_b} \mid C_{i_c})$:

$$\begin{aligned}
&\mathcal{I}(\mathcal{A};\mathcal{B} \mid \mathcal{C}) = \mathrm{H}(\mathcal{A} \mid \mathcal{C}) - \mathrm{H}(\mathcal{A} \mid \mathcal{B},\mathcal{C}) = \\
&\quad = -\sum_{i_c=1}^{n_c}\mathbb{P}(C_{i_c})\sum_{i_a=1}^{n_a}\mathbb{P}(A_{i_a} \mid C_{i_c})\log\mathbb{P}(A_{i_a} \mid C_{i_c}) + \sum_{i_c=1}^{n_c}\sum_{i_b=1}^{n_b}\mathbb{P}(B_{i_b},C_{i_c})\sum_{i_a=1}^{n_a}\mathbb{P}(A_{i_a} \mid B_{i_b},C_{i_c})\log\mathbb{P}(A_{i_a} \mid B_{i_b},C_{i_c}) = \\
&\quad = -\sum_{i_c=1}^{n_c}\mathbb{P}(C_{i_c})\left[\sum_{i_a=1}^{n_a}\mathbb{P}(A_{i_a} \mid C_{i_c})\log\mathbb{P}(A_{i_a} \mid C_{i_c}) - \sum_{i_c=1}^{n_c}\sum_{i_b=1}^{n_b}\mathbb{P}(B_{i_b} \mid C_{i_c})\sum_{i_a=1}^{n_a}\mathbb{P}(A_{i_a} \mid B_{i_b},C_{i_c})\log\mathbb{P}(A_{i_a} \mid B_{i_b},C_{i_c})\right]
\end{aligned}$$

Далее, аналогично доказательству предложения 1.3.13, положим $\mathbb{P}_{i_c}(\cdot) = \mathbb{P}(\cdot \mid C_{i_c})$. Тогда:

$$\mathcal{I}(\mathcal{A};\mathcal{B} \mid \mathcal{C}) = -\sum_{i_c=1}^{n_c}\mathbb{P}(C_{i_c})\left[\overbrace{\sum_{i_a=1}^{n_a}\mathbb{P}_{i_c}(A_{i_a})\log\mathbb{P}_{i_c}(A_{i_a})}^{-\mathrm{H}(\mathcal{A})\text{ относительно }\mathbb{P}_{i_c}} - \overbrace{\sum_{i_c=1}^{n_c}\sum_{i_b=1}^{n_b}\mathbb{P}_{i_c}(B_{i_b})\sum_{i_a=1}^{n_a}\mathbb{P}_{i_c}(A_{i_a} \mid B_{i_b})\log\mathbb{P}_{i_c}(A_{i_a} \mid B_{i_b})}^{-\mathrm{H}(\mathcal{A}|\mathcal{B})\text{ относительно }\mathbb{P}_{i_c}}\right] \geq 0$$

□

Замечание. В отличие от условной энтропии, которая всегда меньше безусловной (information does not hurt), условная взаимная информация может быть меньше, а может быть больше взаимной информации.

Пример (Условная взаимная информация может быть больше безусловной)**.** Пусть опыты $\mathcal{A}_1 = \{O_1,P_1\}, \mathcal{A}_2 = \{O_2,P_2\}$ суть независимые броски честной монеты. Рассмотрим также еще опыт состоящий в наблюдении того, выпало ли на монетках одно и то же значение, или нет

$$\mathcal{C} = \{\textit{Броски дали одинаковый результат}, \textit{Броски дали разный результат}\}.$$

Иначе можно записать $\mathcal{C} = \{(O_1 \cap O_2) \cup (P_1 \cap P_2), (O_1 \cap P_2) \cup (P_1 \cap O_2)\}$. Обратим внимание, что сами броски при этом в опыте $\mathcal{C}$ не наблюдаются. Тогда:

$$\mathcal{I}(\mathcal{A}_1; \mathcal{A}_2) = 0 \quad \text{(в силу независимости опытов } \mathcal{A}_1 \text{ и } \mathcal{A}_2\text{)}.$$

Вычислим условную информацию $\mathcal{I}(\mathcal{A}_1; \mathcal{A}_2 \mid \mathcal{C})$. Поймем, что знание результата опыта $\mathcal{C}$ вместе с результатом одного из бросков (скажем знание результата опыта $\mathcal{A}_1$) полностью определяет результат другого броска. Таким образом, имеем что $\mathrm{H}(\mathcal{A}_2 \mid \mathcal{A}_1, \mathcal{C}) = 0$. С другой стороны

$$\mathbb{P}(O_2 \mid \textit{Броски дали одинаковый результат}) = \mathbb{P}(O_2) \qquad \mathbb{P}(P_2 \mid \textit{Броски дали одинаковый результат}) = \mathbb{P}(P_2)$$
$$\mathbb{P}(O_2 \mid \textit{Броски дали разный результат}) = \mathbb{P}(O_2) \qquad \mathbb{P}(P_2 \mid \textit{Броски дали разный результат}) = \mathbb{P}(P_2)$$

И значит опыты $\mathcal{A}_2$ и $\mathcal{C}$ независимы. Следовательно, $\mathrm{H}(\mathcal{A}_2 \mid \mathcal{C}) = \mathrm{H}(\mathcal{A}_2) = 1$ бит. Но тогда:

$$\mathcal{I}(\mathcal{A}_1; \mathcal{A}_2 \mid \mathcal{C}) = \mathrm{H}(\mathcal{A}_2 \mid \mathcal{C}) - \mathrm{H}(\mathcal{A}_2 \mid \mathcal{A}_1, \mathcal{C}) = 1 - 0 = 1 \text{ бит}.$$

Получили $\mathcal{I}(\mathcal{A}_1; \mathcal{A}_2) = 0 < 1 = \mathcal{I}(\mathcal{A}_1; \mathcal{A}_2 \mid \mathcal{C})$. Условная взаимная информация превосходит безусловную информацию.

Пример (Условная взаимная информация может быть меньше безусловной)**.** Пусть теперь вместо двух бросков честной монеты, мы делаем выбор наугад между фальшивой и настоящей, честной, монетой (как в примерах ранее), после чего подбрасываем такую монету два раза. Будем считать, что фальшивая монета всегда выпадает орлом. Опыт $\mathcal{B}$ будет состоять в раскрытии того, какая монета была вытащена, настоящая или фальшивая $\mathcal{B} = \{\mathrm{H}, \Phi\}$. В свою очередь опыты $\mathcal{A}_1 = \{O_1, P_1\}, \mathcal{A}_2 = \{O_2, P_2\}$, как и ранее, состоят в двух бросках выбранной монеты. Вычислим взаимную информацию $\mathcal{I}(\mathcal{A}_1; \mathcal{A}_2)$ — она будет больше нуля, так как опыты $\mathcal{A}_1$ и $\mathcal{A}_2$ зависимы. Для этого посчитаем:

$$\mathrm{H}(\mathcal{A}_i) = -\mathbb{P}(O_i) \log \mathbb{P}(O_i) - \mathbb{P}(P_i) \log \mathbb{P}(P_i)$$

Полные вероятности $\mathbb{P}(O_i), \mathbb{P}(P_i), i = 1, 2$ можно вычислить из формулы полной вероятности:

$$\mathbb{P}(O_i) = \mathbb{P}(O_i \mid \Phi) \cdot \mathbb{P}(\Phi) + \mathbb{P}(O_i \mid \mathrm{H}) \cdot \mathbb{P}(\mathrm{H}) = 1 \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2} = \frac{3}{4}$$
$$\mathbb{P}(P_i) = \mathbb{P}(P_i \mid \Phi) \cdot \mathbb{P}(\Phi) + \mathbb{P}(P_i \mid \mathrm{H}) \cdot \mathbb{P}(\mathrm{H}) = 0 \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$$

И значит $\mathrm{H}(\mathcal{A}_1) = \mathrm{H}(\mathcal{A}_2) = 2 - \frac{3}{4} \cdot \log 3 \approx 0.81$ бит. Вычислим теперь $\mathrm{H}(\mathcal{A}_1, \mathcal{A}_2)$, для этого надо вычислить совместные вероятности. Аналогично, применяя формулу полной вероятности, получаем

$$\mathbb{P}(O_1, O_2) = \frac{1}{4} \cdot \frac{1}{2} + 1 \cdot \frac{1}{2} = \frac{5}{8} \qquad \mathbb{P}(P_1, O_2) = \frac{1}{4} \cdot \frac{1}{2} + 0 \cdot \frac{1}{2} = \frac{1}{8}$$
$$\mathbb{P}(O_1, P_2) = \frac{1}{4} \cdot \frac{1}{2} + 0 \cdot \frac{1}{2} = \frac{1}{8} \qquad \mathbb{P}(P_1, P_2) = \frac{1}{4} \cdot \frac{1}{2} + 0 \cdot \frac{1}{2} = \frac{1}{8}$$

Откуда $\mathrm{H}(\mathcal{A}_1, \mathcal{A}_2) = 3 - \frac{5}{8} \log 5 \approx 1.55$ бит. Значит:

$$\mathcal{I}(\mathcal{A}_1; \mathcal{A}_2) = \mathrm{H}(\mathcal{A}_1) + \mathrm{H}(\mathcal{A}_2) - \mathrm{H}(\mathcal{A}_1; \mathcal{A}_2) \approx 0.07 \text{ бит}$$

Покажем что $\mathcal{I}(\mathcal{A}_1; \mathcal{A}_2 \mid \mathcal{B}) = 0$. Мы имеем:

$$\mathbb{P}(O_2 \mid O_1, \Phi) = \mathbb{P}(O_2 \mid \Phi) = 1 \qquad \mathbb{P}(P_2 \mid O_1, \Phi) = \mathbb{P}(P_2 \mid \Phi) = 0$$
$$\mathbb{P}(O_2 \mid O_1, \mathrm{H}) = \mathbb{P}(O_2 \mid \mathrm{H}) = 0.5 \qquad \mathbb{P}(P_2 \mid O_1, \mathrm{H}) = \mathbb{P}(P_2 \mid \mathrm{H}) = 0.5$$

Можно убедиться, что $\mathrm{H}(\mathcal{A}_2 \mid \mathcal{B}, \mathcal{A}_1) = \mathrm{H}(\mathcal{A}_2 \mid \mathcal{B})$ (разные скобки в выражении ниже носят только визуальный характер).

$$\begin{aligned}
\mathrm{H}(\mathcal{A}_2 \mid \mathcal{B}, \mathcal{A}_1) = &- \mathbb{P}(O_1, \Phi)\Big[\mathbb{P}(O_2 \mid O_1, \Phi) \log \mathbb{P}(O_2 \mid O_1, \Phi) + \mathbb{P}(P_2 \mid O_1, \Phi) \log \mathbb{P}(P_2 \mid O_1, \Phi)\Big] \\
&- \mathbb{P}(O_1, \text{Ч})\Big\{\mathbb{P}(O_2 \mid O_1, \text{Ч}) \log \mathbb{P}(O_2 \mid O_1, \text{Ч}) + \mathbb{P}(P_2 \mid O_1, \text{Ч}) \log \mathbb{P}(P_2 \mid O_1, \Phi)\Big\} \\
&- \mathbb{P}(P_1, \Phi)\Big[\mathbb{P}(O_2 \mid P_1, \Phi) \log \mathbb{P}(O_2 \mid P_1, \Phi) + \mathbb{P}(P_2 \mid P_1, \Phi) \log \mathbb{P}(P_2 \mid P_1, \Phi)\Big] \\
&- \mathbb{P}(P_1, \text{Ч})\Big\{\mathbb{P}(O_2 \mid P_1, \text{Ч}) \log \mathbb{P}(O_2 \mid P_1, \text{Ч}) + \mathbb{P}(P_2 \mid P_1, \text{Ч}) \log \mathbb{P}(P_2 \mid P_1, \Phi)\Big\} = \\
= &- \Big(\underbrace{\mathbb{P}(O_1, \Phi) + \mathbb{P}(P_1, \Phi)}_{\mathbb{P}(\Phi)}\Big) \cdot \Big[\mathbb{P}(O_2 \mid \Phi) \log \mathbb{P}(O_2 \mid \Phi) + \mathbb{P}(P_2 \mid \Phi) \log \mathbb{P}(P_2 \mid \Phi)\Big] \\
&- \Big(\underbrace{\mathbb{P}(O_1, \text{Ч}) + \mathbb{P}(P_1, \text{Ч})}_{\mathbb{P}(\text{Ч})}\Big) \cdot \Big\{\mathbb{P}(O_2 \mid \text{Ч}) \log \mathbb{P}(O_2 \mid \text{Ч}) + \mathbb{P}(P_2 \mid \text{Ч}) \log \mathbb{P}(P_2 \mid \text{Ч})\Big\} = \mathrm{H}(\mathcal{A}_2 \mid \mathcal{B})
\end{aligned}$$

Значит $\mathcal{I}(\mathcal{A}_1; \mathcal{A}_2 \mid \mathcal{B}) = 0 < \mathcal{I}(\mathcal{A}_1; \mathcal{A}_2)$.

Предложение 1.4.5 (Правило цепочки для взаимной информации)**.**

$$\mathcal{I}_m(\mathcal{A}_1, \ldots, \mathcal{A}_n; \mathcal{B}) = \sum_{i=1}^{n} \mathcal{I}_m(\mathcal{A}_i; \mathcal{B} \mid \mathcal{A}_{i-1}, \ldots, \mathcal{A}_1).$$

Доказательство. Не умаляя общности $m = 2$. Имеем:

$$\begin{aligned}
\mathcal{I}(\mathcal{A}_1, \ldots, \mathcal{A}_n; \mathcal{B}) &= \mathrm{H}(\mathcal{A}_1, \ldots, \mathcal{A}_n) - \mathrm{H}(\mathcal{A}_1, \ldots, \mathcal{A}_n \mid \mathcal{B}) \\
&= \left[\sum_{i=1}^{n} \mathrm{H}(\mathcal{A}_i \mid \mathcal{A}_{i-1}, \ldots, \mathcal{A}_1)\right] - \left[\sum_{i=1}^{n} \mathrm{H}(\mathcal{A}_i \mid \mathcal{B}, \mathcal{A}_{i-1}, \ldots, \mathcal{A}_1)\right] \\
&= \sum_{i=1}^{n} \left[\mathrm{H}(\mathcal{A}_i \mid \mathcal{A}_{i-1}, \ldots, \mathcal{A}_1) - \mathrm{H}(\mathcal{A}_i \mid \mathcal{B}, \mathcal{A}_{i-1}, \ldots, \mathcal{A}_1)\right] \\
&= \sum_{i=1}^{n} \mathcal{I}(\mathcal{A}_i; \mathcal{B} \mid \mathcal{A}_{i-1}, \ldots, \mathcal{A}_1).
\end{aligned}$$

Первый переход использует определение взаимной информации через разность энтропий. Второй переход применяет правило цепочки для безусловной и условной энтропии (следствия 1.3.12 и 1.3.14). Третий — перегруппировка сумм. Четвертый — определение условной взаимной информации. □

1.4.3. Информация взаимодействия

Определение 1.4.6 (Информация взаимодействия)**.** Для трёх опытов $\mathcal{A}$, $\mathcal{B}$, $\mathcal{C}$ информация взаимодействия (или взаимная информация трёх величин) определяется как

$$\mathcal{I}_m(\mathcal{A}; \mathcal{B}; \mathcal{C}) = \mathcal{I}_m(\mathcal{A}; \mathcal{B}) - \mathcal{I}_m(\mathcal{A}; \mathcal{B} \mid \mathcal{C}).$$

Предложение 1.4.7 (Симметричное выражение)**.** *Для трёх опытов $\mathcal{A}, \mathcal{B}, \mathcal{C}$ информация взаимодействия может быть выражена через энтропии по формуле включения-исключения:*

$$\mathcal{I}_m(\mathcal{A}; \mathcal{B}; \mathcal{C}) = \mathrm{H}_m(\mathcal{A}) + \mathrm{H}_m(\mathcal{B}) + \mathrm{H}_m(\mathcal{C}) - \mathrm{H}_m(\mathcal{A}, \mathcal{B}) - \mathrm{H}_m(\mathcal{A}, \mathcal{C}) - \mathrm{H}_m(\mathcal{B}, \mathcal{C}) + \mathrm{H}_m(\mathcal{A}, \mathcal{B}, \mathcal{C}).$$

Доказательство. Не умаляя общности $m = 2$. По определению:

$$\begin{aligned}
\mathcal{I}(\mathcal{A}; \mathcal{B}) - \mathcal{I}(\mathcal{A}; \mathcal{B} \mid \mathcal{C}) &= [\mathrm{H}(\mathcal{A}) - \mathrm{H}(\mathcal{A} \mid \mathcal{B})] - [\mathrm{H}(\mathcal{A} \mid \mathcal{C}) - \mathrm{H}(\mathcal{A} \mid \mathcal{B}, \mathcal{C})] = \\
&= \mathrm{H}(\mathcal{A}) - \mathrm{H}(\mathcal{A} \mid \mathcal{B}) - \mathrm{H}(\mathcal{A} \mid \mathcal{C}) + \mathrm{H}(\mathcal{A} \mid \mathcal{B}, \mathcal{C}).
\end{aligned}$$

Выразим все условные энтропии через совместные, используя правило цепочки:

$$\mathrm{H}(\mathcal{A} \mid \mathcal{B}) = \mathrm{H}(\mathcal{A}, \mathcal{B}) - \mathrm{H}(\mathcal{B}), \quad \mathrm{H}(\mathcal{A} \mid \mathcal{C}) = \mathrm{H}(\mathcal{A}, \mathcal{C}) - \mathrm{H}(\mathcal{C}), \quad \mathrm{H}(\mathcal{A} \mid \mathcal{B}, \mathcal{C}) = \mathrm{H}(\mathcal{A}, \mathcal{B}, \mathcal{C}) - \mathrm{H}(\mathcal{B}, \mathcal{C}).$$

Подставим:

$$\begin{aligned}
\mathcal{I}(\mathcal{A}; \mathcal{B}) - \mathcal{I}(\mathcal{A}; \mathcal{B} \mid \mathcal{C}) &= \mathrm{H}(\mathcal{A}) - [\mathrm{H}(\mathcal{A}, \mathcal{B}) - \mathrm{H}(\mathcal{B})] - [\mathrm{H}(\mathcal{A}, \mathcal{C}) - \mathrm{H}(\mathcal{C})] + [\mathrm{H}(\mathcal{A}, \mathcal{B}, \mathcal{C}) - \mathrm{H}(\mathcal{B}, \mathcal{C})] = \\
&= \mathrm{H}(\mathcal{A}) + \mathrm{H}(\mathcal{B}) + \mathrm{H}(\mathcal{C}) - \mathrm{H}(\mathcal{A}, \mathcal{B}) - \mathrm{H}(\mathcal{A}, \mathcal{C}) - \mathrm{H}(\mathcal{B}, \mathcal{C}) + \mathrm{H}(\mathcal{A}, \mathcal{B}, \mathcal{C}).
\end{aligned}$$

Что и требовалось доказать. □

Следствие 1.4.8 (Симметричность)**.** *Информация взаимодействия симметрична относительно перестановки аргументов:*

$$\mathcal{I}_m(\mathcal{A}; \mathcal{B}; \mathcal{C}) = \mathcal{I}_m(\mathcal{A}; \mathcal{C}; \mathcal{B}) = \mathcal{I}_m(\mathcal{B}; \mathcal{A}; \mathcal{C}) = \mathcal{I}_m(\mathcal{B}; \mathcal{C}; \mathcal{A}) = \mathcal{I}_m(\mathcal{C}; \mathcal{A}; \mathcal{B}) = \mathcal{I}_m(\mathcal{C}; \mathcal{B}; \mathcal{A}).$$

Доказательство. Непосредственно следует из симметричности выражения через совместные энтропии, которое инвариантно относительно перестановок $\mathcal{A}, \mathcal{B}, \mathcal{C}$. □

Предложение 1.4.9 (Границы информации взаимодействия)**.** *Для любых трёх опытов $\mathcal{A}, \mathcal{B}, \mathcal{C}$:*

$$-\min\{\mathcal{I}_m(\mathcal{A}; \mathcal{B} \mid \mathcal{C}), \mathcal{I}_m(\mathcal{A}; \mathcal{C} \mid \mathcal{B}), \mathcal{I}_m(\mathcal{B}; \mathcal{C} \mid \mathcal{A})\} \le \mathcal{I}_m(\mathcal{A}; \mathcal{B}; \mathcal{C}) \le \min\{\mathcal{I}_m(\mathcal{A}; \mathcal{B}), \mathcal{I}_m(\mathcal{A}; \mathcal{C}), \mathcal{I}_m(\mathcal{B}; \mathcal{C})\}.$$

Доказательство. Не умаляя общности $m = 2$. Имеем из определения, что $-\mathcal{I}(\mathcal{A}; \mathcal{B} \mid \mathcal{C}) \le \mathcal{I}(\mathcal{A}; \mathcal{B}; \mathcal{C}) \le \mathcal{I}(\mathcal{A}; \mathcal{B})$. В силу симметричности получаем остальные неравенства, откуда следует искомое. □

Замечание. Неравенства точные: границы достигаются в примерах из предыдущей подсекции.

Замечание. Границы в предложении 1.4.9 точны, достаточно рассмотреть примеры про броски монеты из предыдущей подсекции. В частности, информация взаимодействия **может быть отрицательной**. При этом довольно часто, информацию взаимодействия представляют с помощью кругов Эйлера, см. рис. 1.4; однако, такое представление может запутать, и создать впечатление что $\mathcal{I}(\mathcal{A};\mathcal{B};\mathcal{C}) \geq 0$, что вовсе не обязательно.

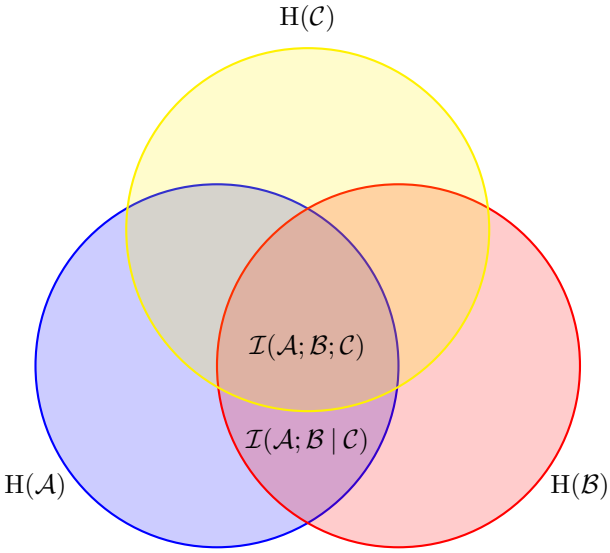

Рис. 1.4: *Информация взаимодействия* $\mathcal{I}(\mathcal{A};\mathcal{B})$

Замечание. Информация взаимодействия измеряет влияние опыта $\mathcal{C}$ на взаимную информацию между $\mathcal{A}$ и $\mathcal{B}$:

- $\mathcal{I}(\mathcal{A};\mathcal{B};\mathcal{C}) = 0$: $\mathcal{C}$ не влияет на взаимную информацию;
- $\mathcal{I}(\mathcal{A};\mathcal{B};\mathcal{C}) > 0$: знание $\mathcal{C}$ в среднем уменьшает взаимную информацию между $\mathcal{A}$ и $\mathcal{B}$ (часть общих сведений объясняется $\mathcal{C}$);
- $\mathcal{I}(\mathcal{A};\mathcal{B};\mathcal{C}) < 0$: знание $\mathcal{C}$ в среднем увеличивает взаимную информацию между $\mathcal{A}$ и $\mathcal{B}$ (обнаруживает скрытую зависимость).

1.5. Энтропия случайных величин

Оглавление

1.5.1 Энтропия дискретных случайных величин . . . 27
1.5.2 Дифференциальная энтропия . . . 28
1.5.3 Условная и совместная дифференциальная энтропия . . . 30

1.5.1. Энтропия дискретных случайных величин

Пусть $\xi_1, \dots, \xi_n$ — набор дискретных случайных величин, принимающих значения из конечных множеств $\mathcal{X}_1, \dots, \mathcal{X}_n$ соответственно. С ними естественным образом можно связать полную систему событий — опыт:

$$\mathcal{A}(\xi_1, \dots, \xi_n) = \big\{\{\xi_1 = x_1, \dots, \xi_n = x_n\} \;\big|\; x_1 \in \mathcal{X}_1, \dots, x_n \in \mathcal{X}_n\big\},$$

где вероятность события определяется совместным распределением:

$$\mathbb{P}(\xi_1 = x_1, \dots, \xi_n = x_n) = p_{\xi_1 \dots \xi_n}(x_1, \dots, x_n).$$

Определение 1.5.1 (Энтропия случайной величины)**.** Энтропией дискретной случайной величины ξ называется энтропия соответствующего опыта:

$$\mathrm{H}_m(\xi) := \mathrm{H}_m(\mathcal{A}(\xi)) = -\sum_{x \in \mathcal{X}} p_\xi(x) \log_m p_\xi(x)$$

Определение 1.5.2 (Совместная энтропия)**.** Совместной энтропией набора случайных величин $\xi_1, \dots, \xi_n$ называется энтропия опыта, соответствующего их совместному распределению:

$$\mathrm{H}_m(\xi_1, \dots, \xi_n) := \mathrm{H}_m(\mathcal{A}(\xi_1, \dots, \xi_n)) = -\sum_{x_1, \dots, x_n} p_{\xi_1 \dots \xi_n}(x_1, \dots, x_n) \log_m p_{\xi_1 \dots \xi_n}(x_1, \dots, x_n),$$

где сумма идет по всем возможным значениям $x_1, \dots, x_n$ величин $\xi_1, \dots, \xi_n$;

Определение 1.5.3 (Условная энтропия)**.** Условной энтропией ξ при условии η называется условная энтропия соответствующих опытов:

$$\mathrm{H}_m(\xi \mid \eta) := \mathrm{H}_m(\mathcal{A}(\xi) \mid \mathcal{A}(\eta)) = -\sum_{y \in \mathcal{Y}} p_\eta(y) \sum_{x \in \mathcal{X}} p_{\xi|\eta}(x|y) \log_m p_{\xi|\eta}(x|y)$$

где $p_{\xi|\eta}(x|y)$ означает условную вероятность $\mathbb{P}(\xi = x \mid \eta = y)$

Предложение 1.5.4 (Переход от опытов к случайным величинам)**.** *Пусть $\mathcal{A}$ и $\mathcal{B}$ — два опыта. Тогда существуют дискретные случайные величины ξ и η такие, что:*

$$\mathcal{A} = \mathcal{A}(\xi), \quad \mathcal{B} = \mathcal{A}(\eta),$$

и все теоретико-информационные характеристики сохраняются.

Доказательство. Достаточно положить $\xi(\omega) = i_a$, если реализовалось событие $A_{i_a} \in \mathcal{A}$, и аналогично для η. Тогда распределение ξ в точности совпадает с распределением исходов опыта $\mathcal{A}$, и все энтропийные величины (совместная, условная энтропия, взаимная информация) переходят в соответствующие характеристики случайных величин. □

Следствие 1.5.5 (Независимость случайных величин)**.** *Случайные величины ξ и η независимы тогда и только тогда, когда соответствующие опыты $\mathcal{A}(\xi)$ и $\mathcal{A}(\eta)$ независимы, что эквивалентно:*

$$\mathrm{H}_m(\xi, \eta) = \mathrm{H}_m(\xi) + \mathrm{H}_m(\eta) \quad \Longleftrightarrow \quad \mathcal{I}_m(\xi; \eta) = 0.$$

Доказательство. Следует напрямую из определения. □

Следствие 1.5.6 (Функциональная зависимость)**.** *Дискретная случайная величина ξ является функцией от дискретной случайной величины η (т.е. $\xi = f(\eta)$ п.н. для некоторой детерминированной функции f) тогда и только тогда, когда опыт $\mathcal{A}(\xi)$ определяется опытом $\mathcal{A}(\eta)$, что эквивалентно:*

$$\mathrm{H}_m(\xi \mid \eta) = 0 \quad \Longleftrightarrow \quad \mathcal{I}_m(\xi; \eta) = \mathrm{H}_m(\xi).$$

Доказательство. Не умаляя общности, пусть $m = 2$, ξ принимает значения из множества $\mathcal{X}$, η принимает значения из множества $\mathcal{Y}$. В силу предложения 1.3.3, для любого $x \in \mathcal{X}$ существует единственный $y_x \in \mathcal{Y}$ такой, что:

$$\mathbb{P}(\xi = x \mid \eta = y_x) = 1 \quad \mathbb{P}(\xi \neq x \mid \eta = y_x) = 0$$

Положим $f(x) = y_x$. Тогда $\xi = f(\eta)$ почти наверное, что и требовалось доказать. □

Замечание (О терминологии). В дальнейшем мы будем использовать обозначения $\mathrm{H}(\xi)$, $\mathrm{H}(\xi, \eta)$, $\mathrm{H}(\xi \mid \eta)$, $\mathcal{I}(\xi; \eta)$ для энтропийных характеристик случайных величин, подразумевая соответствующие характеристики опытов $\mathcal{A}(\xi)$, $\mathcal{A}(\eta)$. Все свойства, доказанные для опытов, автоматически переносятся на случайные величины.

1.5.2. Дифференциальная энтропия

Определение 1.5.7 (Дифференциальная энтропия)**.** Пусть η — абсолютно непрерывная случайная величина (вектор) с плотностью распределения $p(\mathbf{x})$, заданной на $\mathbb{R}^d$. Дифференциальная энтропия (или энтропия непрерывного распределения с плотностью p) определяется как:

$$h_m(\xi) = h_m(p) = -\int\limits_{\mathbb{R}^d} p(\mathbf{x}) \log_m p(\mathbf{x})\, d\mathbf{x},$$

Замечание. Как и ранее, считается что $0 \cdot \log 0 = 0$.

Замечание. Дифференциальная энтропия может не существовать. Например, можно убедиться что для случайной величины с плотностью распределения

$$f(x) = \begin{cases} \frac{\log 2}{x \log^2(x)} & x \geq 2 \\ 0 & x < 2 \end{cases}$$

интеграл из определения диффернциальной энтропии разойдется. Однако, для абсолютно-непрерывных случайных величин ξ, у которых носитель $\operatorname{supp}(\xi) = \operatorname{Cl}\big(\{\mathbf{x} \in \mathbb{R}^d \mid p_\xi(\mathbf{x}) > 0\}\big)$ компактен, диффернциальная энтропия конечна.

Нотация. Для диффернциальной энтропии стандартным основанием будем считать e: $h(\xi) = h_e(\xi)$

Пример (Равномерное распределение)**.** Пусть $\xi \sim \mathcal{U}(a, b)$, тогда $p_\xi(x) = \frac{1}{b-a}$ на $[a, b]$.

$$h(\xi) = -\int_a^b \frac{1}{b-a} \ln \frac{1}{b-a}\, dx = \ln(b-a) \ \text{ нат.}$$

При $b - a < 1$ дифференциальная энтропия отрицательна.

Неравенство Гиббса — непрерывный случай

Лемма 1.5.8 (Неравенство Гиббса — непрерывный случай)**.** *Пусть $p_\xi(\mathbf{x})$, $p_\eta(\mathbf{x})$ — плотности случайных величин ξ и η, причем для любого $\mathbf{x} \in \mathbb{R}^d$ выполнено, что $p_\eta(\mathbf{x}) = 0 \Rightarrow p_\xi(\mathbf{x}) = 0$. Тогда:*

$$-\int\limits_{\mathbb{R}^d} p_\xi(\mathbf{x}) \log_m p_\xi(\mathbf{x})\, d\mathbf{x} \leq -\int\limits_{\mathbb{R}^d} p_\xi(\mathbf{x}) \log_m p_\eta(\mathbf{x})\, d\mathbf{x}$$

Причем равенство тогда и только тогда, когда $p_\xi = p_\eta$ почти всюду.

Доказательство. Запишем неравенство в следующем виде[6]:

$$\int\limits_{\mathbb{R}^d} p_\xi(\mathbf{x}) \log \frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})}\, d\mathbf{x} \leq 0$$

Дальше, поскольку $p_\xi(\mathbf{x})\, d\mathbf{x} = d\mathbb{P}_\xi$ (где $\mathbb{P}_\xi$ — распределение ξ), мы можем записать неравенство в виде:

$$\int\limits_{\mathbb{R}^d} \log \frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})}\, d\mathbb{P}_\xi \leq 0$$

[6] Здесь и далее, считаем что $0 \cdot \log \frac{0}{0} = 0$

Применим неравенство Йенсена:

$$\int\limits_{\mathbb{R}^d} \log \frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})}\, d\mathbb{P}_\xi \le \log\left(\int\limits_{\mathbb{R}^d} \frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})}\, d\mathbb{P}_\xi\right)$$

Дальше, заметим что $\frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})} = \frac{d\mathbb{P}_\eta}{d\mathbb{P}_\xi}$; поэтому

$$\int\limits_{\mathbb{R}^d} \frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})}\, d\mathbb{P}_\xi = \int\limits_{\mathbb{R}^d} d\mathbb{P}_\eta = 1$$

Откуда:

$$\int\limits_{\mathbb{R}^d} \log \frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})}\, d\mathbb{P}_\xi = \int\limits_{\mathbb{R}^d} \log \frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})}\, d\mathbb{P}_\xi \le \log\left(\int\limits_{\mathbb{R}^d} \frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})}\, d\mathbb{P}_\xi\right) = \log\left(\int\limits_{\mathbb{R}^d} \frac{p_\eta(\mathbf{x})}{p_\xi(\mathbf{x})}\, d\mathbb{P}_\xi\right) = \log\left(\int\limits_{\mathbb{R}^d} d\mathbb{P}_\eta\right) = \log(1) = 0$$

Что и требовалось доказать. Равенство достигается тогда и только тогда, когда $\frac{p_\xi}{p_\eta}$ постоянна почти всюду. Из условия $\int_{\mathbb{R}^d} p_\xi(\mathbf{x})\, d\mathbf{x} = \int_{\mathbb{R}^d} p_\eta(\mathbf{x})\, d\mathbf{x} = 1$, получаем что $p_\xi = p_\eta$ почти всюду. □

Следствие 1.5.9 (Максимум дифференциальной энтропии на отрезке)**.** *Среди всех абсолютно непрерывных распределений, сосредоточенных на отрезке $[a, b]$, максимальную дифференциальную энтропию имеет равномерное распределение $\mathcal{U}(a, b)$, и она равна $\log_m(b - a)$.*

Доказательство. Пусть $p(x)$ — произвольная плотность на $[a, b]$, $q(x) = \frac{1}{b-a}$ — плотность равномерного распределения. По неравенству Гиббса (лемма 1.5.8):

$$h_m(p) = -\int_a^b p(x) \ln p(x)\, dx \le -\int_a^b p(x) \ln q(x)\, dx = -\int_a^b p(x) \log \frac{1}{b-a}\, dx = \log(b - a).$$

Равенство достигается при $p = q$ почти всюду. □

Замечание (Связь с дискретной энтропией через квантование). Если дискретизировать непрерывную случайную величину ξ с шагом Δ, рассматривая $\xi^\Delta = i\Delta$ при $x \in [i\Delta, (i + 1)\Delta), i \in \mathbb{Z}$, то при малых Δ:

$$\begin{aligned}\mathrm{H}_m\big(\xi^\Delta\big) = -\sum_i \mathbb{P}(\xi \in [i\Delta; (i+1)\Delta)) \log_m \mathbb{P}(\xi \in [i\Delta; (i+1)\Delta)) \approx \\ -\sum_i p_\xi(x_i)\Delta \log_m(p_\xi(x_i)\Delta) = -\sum_i p_\xi(x_i)\Delta \log_m(p_\xi(x_i)\Delta) - \log_m \Delta \sum_i p_\xi(x_i)\Delta \\ \approx -\int f(x) \log_m f(x)\, dx - \log_m \Delta.\end{aligned}$$

Таким образом,

$$h_m(\xi) = \lim_{\Delta \to 0} [\mathrm{H}_m\big(\xi^\Delta\big) + \log_m \Delta].$$

Дифференциальная энтропия — это предел энтропии Шеннона с точностью до аддитивной константы, стремящейся к бесконечности. В связи с этим, можно было бы ожидать что многие свойства энтропии Шеннона сохранятся, однако это не так: например $h(\xi)$ может принимать нулевое или даже отрицательные значения. Также, в отличие от энтропии Шеннона, дифференциальная энтропия не инвариантна при замене переменных: для дискретной случайной величины ξ и любой биекции g энтропия $g(\xi)$ будет совпадать с ξ, в то время как у дифференциальной энтропии это не так.

Предложение 1.5.10 (Замена переменных)**.** *Пусть $g\colon \mathbb{R}^d \to \mathbb{R}^d$ — диффеоморфизм, $\xi = g(\eta)$. Тогда:*

$$h_m(\eta) = h_m(\xi) - \int\limits_{\mathbb{R}^d} p_\xi(\mathbf{x}) \log_m |\det J_g(\mathbf{x})|\, d\mathbf{x}$$

где $J_g(\mathbf{x})$ — матрица Якоби преобразования g.

Доказательство. Не умаляя общности $m = e$. Вычислим $\mathbb{P}(\eta \in A)$ для произвольного A двумя способами:

$$\mathbb{P}(\eta \in A) = \int\limits_A p_\eta(\mathbf{x})\, d\mathbf{x} = \int\limits_{g(A)} p_\xi(\mathbf{y})\, d\mathbf{y} \overset{\mathbf{y}=g(\mathbf{x})}{=} \int\limits_A p_\xi(g((\mathbf{x}))|\det J_g(\mathbf{x})|\, d\mathbf{x}.$$

Значит, плотность η выражается через плотность ξ по следующей формуле замены переменных:

$$p_\eta(\mathbf{x}) = p_\xi(g(\mathbf{x})) \cdot |\det J_g(\mathbf{x})|$$

Вычислим дифференциальную энтропию η:

$$\begin{aligned} h(\eta) &= -\int\limits_{\mathbb{R}^d} p_\eta(\mathbf{x}) \ln p_\eta(\mathbf{x})\, d\mathbf{x} = -\int\limits_{\mathbb{R}^d} p_\xi(g(\mathbf{x})) \cdot |\det J_g(\mathbf{x})| \cdot \ln(p_\xi(g(\mathbf{x})) \cdot |\det J_g(\mathbf{x})|)\, d\mathbf{x} \\ &= -\int\limits_{\mathbb{R}^d} p_\xi(g(\mathbf{x})) \cdot \ln(p_\xi(g(\mathbf{x}))) \cdot |\det J_g(\mathbf{x})|\, d\mathbf{x} - \int_{\mathbb{R}^d} p_\xi(\mathbf{x}) \ln|\det J_g(\mathbf{x})|\, d\mathbf{x} \\ &= -\int\limits_{\mathbb{R}^d} p_\xi(\mathbf{y}) \cdot \ln p_\xi(\mathbf{y})\, d\mathbf{y} - \int\limits_{\mathbb{R}^d} p_\xi(\mathbf{x}) \ln|\det J_g(\mathbf{x})|\, d\mathbf{x} = h(\xi) - \int\limits_{\mathbb{R}^d} p_\xi(\mathbf{x}) \ln|\det J_g(\mathbf{x})|\, d\mathbf{x} \end{aligned}$$

□

Следствие 1.5.11 (Сдвиг)**.** *Если $\xi = \eta + \mathbf{b}$ для случайного вектора $\xi \in \mathbb{R}^d$ и вектора $\mathbf{b} \in \mathbb{R}^d$, то:*

$$h_m(\eta) = h_m(\xi)$$

Следствие 1.5.12 (Масштабирование)**.** *Если $\xi = A\eta$ для случайного вектора $\xi \in \mathbb{R}^d$ и невырожденной матрицы A, то:*

$$h_m(\eta) = h_m(\xi) - \log_m|\det A|.$$

1.5.3. Условная и совместная дифференциальная энтропия

Определение 1.5.13 (Совместная дифференциальная энтропия)**.** Пусть $\xi_1, \ldots, \xi_n$ — абсолютно непрерывные случайные величины (векторы) с совместной плотностью распределения $p_{\xi_1 \ldots \xi_n}(\mathbf{x}_1, \ldots, \mathbf{x}_n)$, заданной на $\mathbb{R}^d, d = d_1 + \ldots + d_n$. Совместной дифференциальной энтропией набора $\xi_1, \ldots, \xi_n$ называется величина:

$$h_m(\xi_1, \ldots, \xi_n) := -\int\limits_{\mathbb{R}^d} p_{\xi_1 \ldots \xi_n}(\mathbf{x}_1, \ldots, \mathbf{x}_n) \log_m p_{\xi_1 \ldots \xi_n}(\mathbf{x}_1, \ldots, \mathbf{x}_n)\, d\mathbf{x}_1 \ldots d\mathbf{x}_n.$$

Определение 1.5.14 (Условная дифференциальная энтропия)**.** Пусть ξ и η — абсолютно непрерывные случайные величины (векторы) с совместной плотностью распределения $p_{\xi,\eta}(\mathbf{x}, \mathbf{y})$ и условной плотностью $p_{\xi|\eta}(\mathbf{x}|\mathbf{y}) = \frac{p_{\xi\eta}(\mathbf{x},\mathbf{y})}{p_\eta(\mathbf{y})}$. Условной дифференциальной энтропией ξ при условии η называется величина:

$$h_m(\xi|\eta) := -\int\limits_{\mathbb{R}^{d_1}} p_\eta(\mathbf{y}) \int\limits_{\mathbb{R}^{d_2}} p_{\xi|\eta}(\mathbf{x}|\mathbf{y}) \log_m p_{\xi|\eta}(\mathbf{x}|\mathbf{y})\, d\mathbf{x}\, d\mathbf{y},$$

где d_1 – размерность η, d_2 — размерность ξ.

Замечание. Из теоремы Фубини, для достаточно «хорошей» совместной плотности, можем получить что:

$$h_m(\xi|\eta) = -\int\limits_{\mathbb{R}^{d_1+d_2}} p_{\xi\eta}(\mathbf{x}, \mathbf{y}) \log_m p_{\xi|\eta}(\mathbf{x}|\mathbf{y})\, d\mathbf{x}\, d\mathbf{y}.$$

Предложение 1.5.15 (Правило цепочки для дифференциальной энтропии)**.** *Для абсолютно непрерывных случайных величин ξ и η выполняется соотношение:*

$$h_m(\xi, \eta) = h_m(\xi) + h_m(\eta|\xi) = h_m(\eta) + h_m(\xi|\eta).$$

В общем случае для набора $\xi_1, \ldots, \xi_n$:

$$h_m(\xi_1, \ldots, \xi_n) = \sum_{i=1}^{n} h_m(\xi_i|\xi_{i-1}, \ldots, \xi_1).$$

Доказательство. Доказательство повторяет рассуждения дискретного случая mutatis mutandis. Для базового случая заметим, что $p_{\xi\eta}(\mathbf{x}, \mathbf{y}) = p_\xi(\mathbf{x}) p_{\eta|\xi}(\mathbf{y}|\mathbf{x})$. Тогда (интегралы берутся по всему пространству):

$$h_m(\xi, \eta) = -\iint p_{\xi\eta}(\mathbf{x}, \mathbf{y}) \log_m p_{\xi\eta}(\mathbf{x}, \mathbf{y})\, d\mathbf{x}\, d\mathbf{y}$$

$$= -\iint p_{\xi\eta}(\mathbf{x},\mathbf{y}) \log_m \big(p_\xi(\mathbf{x}) p_{\eta|\xi}(\mathbf{y}|\mathbf{x})\big)\, d\mathbf{x}\, d\mathbf{y}$$
$$= -\iint p_{\xi\eta}(\mathbf{x},\mathbf{y}) \log_m p_\xi(\mathbf{x})\, d\mathbf{x}\, d\mathbf{y} - \iint p_{\xi\eta}(\mathbf{x},\mathbf{y}) \log_m p_{\eta|\xi}(\mathbf{y}|\mathbf{x})\, d\mathbf{x}\, d\mathbf{y}.$$

В первом слагаемом интегрирование по $\mathbf{y}$ даёт единицу, и оно превращается в $-\int p_\xi(\mathbf{x}) \log_m p_\xi(\mathbf{x})\, d\mathbf{x} = h_m(\xi)$. Второе слагаемое в точности равно $h_m(\eta|\xi)$ по определению. Общий случай доказывается последовательным применением правила цепочки. □

Предложение 1.5.16 (Свойства условной дифференциальной энтропии)**.** *Для абсолютно непрерывных случайных величин ξ и η справедливы следующие свойства:*

1. ***Убывание по условию:*** *$h_m(\xi|\eta) \le h_m(\xi)$, причём равенство достигается тогда и только тогда, когда ξ и η независимы.*

2. ***Условный аналог правила цепочки:***
$$h_m(\xi,\eta|\zeta) = h_m(\xi|\zeta) + h_m(\eta|\xi,\zeta).$$

Доказательство.

1. Используя и неравенство Гиббса (лемма 1.5.8):
$$h_m(\xi) - h_m(\xi|\eta) = \iint p_{\xi\eta}(\mathbf{x},\mathbf{y}) \log_m \frac{p_{\xi|\eta}(\mathbf{x}|\mathbf{y})}{p_\xi(\mathbf{x})}\, d\mathbf{x}\, d\mathbf{y} = \iint p_{\xi\eta}(\mathbf{x},\mathbf{y}) \log_m \frac{p_{\xi\eta}(\mathbf{x},\mathbf{y})}{p_\xi(\mathbf{x}) p_\eta(\mathbf{y})}\, d\mathbf{x}\, d\mathbf{y} \ge 0,$$
Равенство достигается тогда и только тогда, когда $p_{\xi\eta}(\mathbf{x},\mathbf{y}) = p_\xi(\mathbf{x}) p_\eta(\mathbf{y})$ почти всюду, что эквивалентно независимости ξ и η.

2. Следует из применения правила цепочки к условным распределениям.

□

Замечание. При этом, в отличие от дискретного случая, добавление новых случайных величин может как увеличивать, так и уменьшать дифференциальную энтропию. Например, для независимых $\xi, \eta \sim \mathcal{U}(0, \frac{1}{2})$ имеем $h_2(\xi) = h_2(\eta) = -1$, $h_2(\xi,\eta) = -2$.

Предложение 1.5.17 (Свойства совместной дифференциальной энтропии)**.** *Для абсолютно непрерывных случайных величин $\xi_1, \ldots, \xi_n$ справедливы следующие свойства:*

1. ***Симметричность:*** *$h_m(\xi_1, \ldots, \xi_n)$ симметрична относительно перестановки аргументов.*

2. ***Субардитивность:***
$$h_m(\xi_1, \ldots, \xi_n) \le \sum_{i=1}^n h_m(\xi_i),$$
причём равенство достигается тогда и только тогда, когда $\xi_1, \ldots, \xi_n$ независимы в совокупности.

Доказательство. Симметричность непосредственно следует из определения.

Субардитивность докажем по индукции, используя правило цепочки (предложение 1.5.15) и свойство убывания по условию (предложение 1.5.16):

$$\begin{aligned} h_m(\xi_1, \ldots, \xi_n) &= h_m(\xi_1) + h_m(\xi_2, \ldots, \xi_n|\xi_1) \\ &\le h_m(\xi_1) + \sum_{i=2}^n h_m(\xi_i|\xi_1, \ldots, \xi_{i-1}) \quad \text{(по индукции)} \\ &\le h_m(\xi_1) + \sum_{i=2}^n h_m(\xi_i) \quad \text{(по свойству убывания по условию).} \end{aligned}$$

Равенство достигается тогда и только тогда, когда для каждого i выполнено $h_m(\xi_i|\xi_1, \ldots, \xi_{i-1}) = h_m(\xi_i)$, что эквивалентно тому что $p_{\xi_i|\xi_{i-1},\ldots,\xi_1}(\mathbf{x}_i|\mathbf{x}_{i-1}, \ldots, \mathbf{x}_1) = p_{\xi_i}(\mathbf{x}_i)$, и значит:

$$p_{\xi_1,\ldots,\xi_n}(\mathbf{x}_1, \ldots, \mathbf{x}_n) = \prod_{i=1}^n p_{\xi_i|\xi_{i-1},\ldots,\xi_1}(\mathbf{x}_i|\mathbf{x}_{i-1}, \ldots, \mathbf{x}_1) = \prod_{i=1}^n p_{\xi_i}(\mathbf{x}_i).$$

Что означает что $\xi_1, \ldots, \xi_n$ независимы в совокупности. □

1.6. Кросс-энтропия. Дивергенция Кульбака-Лейблера

Оглавление

1.6.1 Кросс-энтропия 32
1.6.2 Дивергенция Кульбака-Лейблера 32
1.6.3 Взаимная информация между случайными величинами 33

1.6.1. Кросс-энтропия

Перед тем как вводить дивергенцию Кульбака–Лейблера, полезно рассмотреть более простую величину — кросс-энтропию. Она измеряет «среднюю удивлённость» при использовании модели q для кодирования данных, порождённых истинным распределением p.

Определение 1.6.1 (Кросс-энтропия для дискретных распределений)**.** Пусть p и q — два распределения на одном и том же конечном множестве $\mathcal{X}$ (вероятностные функции). Кросс-энтропией из p в q называется величина

$$\mathrm{CE}_m(p \parallel q) = -\sum_{x \in \mathcal{X}} p(x) \log_m q(x).$$

Замечание (Связь с энтропией Шеннона)*.* Если $q = p$, то кросс-энтропия превращается в обычную энтропию Шеннона:

$$\mathrm{CE}_m(p \parallel p) = -\sum_{x} p(x) \log_m p(x) = \mathrm{H}_m(p).$$

Предложение 1.6.2 (Нижняя граница кросс-энтропии)**.** *Для любых распределений p и q на $\mathcal{X}$ выполнено:*

$$\mathrm{CE}_m(p \parallel q) \geq \mathrm{H}_m(p),$$

причём равенство достигается тогда и только тогда, когда $p = q$.

Доказательство. Переформулировка неравенства Гиббса (лемма 1.2.2) □

Определение 1.6.3 (Дифференциальная кросс-энтропия)**.** Пусть p и q — две плотности распределений на $\mathbb{R}^d$, причём носитель p содержится в носителе q (т.е. $q(\mathbf{x}) = 0 \Rightarrow p(\mathbf{x}) = 0$ для почти всех $\mathbf{x}$). Дифференциальной кросс-энтропией из p в q называется величина

$$\mathrm{CE}_m(p \parallel q) = -\int_{\mathbb{R}^d} p(\mathbf{x}) \log_m q(\mathbf{x})\, d\mathbf{x}.$$

Предложение 1.6.4 (Неравенство Гиббса для дифференциальной кросс-энтропии)**.** *Для любых плотностей p и q выполнено, таких что $\mathrm{CE}_m(p \parallel q)$ определена:*

$$\mathrm{CE}_m(p \parallel q) \geq h_m(p),$$

где $h_m(p)$ — дифференциальная энтропия распределения p. Равенство достигается тогда и только тогда, когда $p = q$ почти всюду.

Доказательство. Следует из неравенства Гиббса (лемма 1.5.8). Условие равенства также следует из леммы. □

1.6.2. Дивергенция Кульбака-Лейблера

Определение 1.6.5 (Дивергенция Кульбака–Лейблера)**.** Пусть P и Q — два распределения на одном и том же измеримом пространстве, причем P абсолютно непрерывно относительно Q ($P \ll Q$). Дивергенция Кульбака–Лейблера (или относительная энтропия) определяется как:

$$D_{\mathrm{KL}}(P \parallel Q) = \int \log_m \left(\frac{dP}{dQ} \right) dP,$$

где $\frac{dP}{dQ}$ — плотность P относительно Q (существует по теореме Радона-Никодима).
В случае дискретных распределений с вероятностными функциями $p(x)$ и $q(x)$:

$$D_{\mathrm{KL}}(p \parallel q) = \sum_{x} p(x) \log_m \frac{p(x)}{q(x)}.$$

В случае непрерывных распределений с плотностями $p(\mathbf{x})$ и $q(\mathbf{x})$:

$$D_{\mathrm{KL}}(p \parallel q) = \int p(\mathbf{x}) \log_m \frac{p(\mathbf{x})}{q(\mathbf{x})}\, d\mathbf{x}.$$

Предложение 1.6.6 (Неотрицательность дивергенции Кульбака–Лейблера)**.** *Для любых распределений P и Q таких, что $P \ll Q$, выполнено:*

$$D_{\mathrm{KL}}(P \parallel Q) \geq 0,$$

причём равенство достигается тогда и только тогда, когда $P = Q$ почти всюду.

Доказательство. В дискретном случае утверждение следует непосредственно из неравенства Гиббса (лемма **??**). В непрерывном случае — из леммы 1.5.8, применённой к плотностям p и q. В общем случае мер произвольной природы доказательство использует неравенство Йенсена для вогнутой функции $\log_m$ и тот факт, что $\int \frac{dP}{dQ}\, dQ = 1$. □

Предложение 1.6.7 (Связь с энтропией)**.** *Для дискретного распределения p на конечном множестве $\mathcal{X}$ мощности $|\mathcal{X}|$ выполнено:*

$$\mathrm{H}_m(p) = \log_m |\mathcal{X}| - D_{\mathrm{KL}}(p \parallel u),$$

где u — равномерное распределение на $\mathcal{X}$.

Доказательство. Вычислим:

$$D_{\mathrm{KL}}(p \parallel u) = \sum_x p(x) \log_m \frac{p(x)}{1/|\mathcal{X}|} = \sum_x p(x) \log_m p(x) + \log_m |\mathcal{X}| \sum_x p(x) = -\mathrm{H}_m(p) + \log_m |\mathcal{X}|.$$

Откуда непосредственно получаем требуемое равенство. □

Замечание. Дивергенция Кульбака–Лейблера не является метрикой, так как она не симметрична ($D_{\mathrm{KL}}(P\|Q) \neq D_{\mathrm{KL}}(Q\|P)$ вообще говоря) и не удовлетворяет неравенству треугольника. Тем не менее, она обладает важным свойством неотрицательности и играет ключевую роль в теории информации, статистике и машинном обучении как мера «расстояния» между распределениями.

1.6.3. Взаимная информация между случайными величинами

Определение 1.6.8 (Взаимная информация)**.** Для случайных величин ξ и η с совместным распределением $\mathbb{P}_{\xi,\eta}$ и маргинальными $\mathbb{P}_\xi$, $\mathbb{P}_\eta$ взаимная информация определяется как:

$$\mathcal{I}_m(\xi;\eta) = D_{\mathrm{KL}}(\mathbb{P}_{\xi;\eta} \parallel \mathbb{P}_\xi \otimes \mathbb{P}_\eta).$$

В дискретном случае:

$$\mathcal{I}_m(\xi;\eta) = \sum_{x,y} p_{\xi,\eta}(x,y) \log_m \frac{p_{\xi,\eta}(x,y)}{p_\xi(x) p_\eta(y)}.$$

В непрерывном случае:

$$\mathcal{I}_m(\xi;\eta) = \iint f_{\xi;\eta}(\mathbf{x},\mathbf{y}) \log_m \frac{f_{\xi,\eta}(\mathbf{x},\mathbf{y})}{f_\xi(\mathbf{x}) f_\eta(\mathbf{y})}\, d\mathbf{x}\, d\mathbf{y}.$$

Предложение 1.6.9 (Эквивалентные формы)**.** *Взаимная информация может быть выражена через энтропии:*

$$\mathcal{I}(X;Y) = \mathrm{H}(X) - \mathrm{H}(X \mid Y) = \mathrm{H}(Y) - \mathrm{H}(Y \mid X) = \mathrm{H}(X) + \mathrm{H}(Y) - \mathrm{H}(X,Y).$$

Для непрерывных случайных величин аналогично:

$$\mathcal{I}(X;Y) = h(X) - h(X|Y) = h(Y) - h(Y|X) = h(X) + h(Y) - h(X,Y).$$

Доказательство. Непосредственно следует из определений энтропии и условной энтропии. □

ГЛАВА 2

Некоторые приложения

Тот факт, что [данный] многочлен является приближением, необязательно уменьшает его полезность, поскольку все модели являются приближениями. В сущности, все модели неверны, но некоторые из них полезны.

Джордж Бокс, британский статистик

Оглавление

2.1 Элементарные приложения 35
2.1.1 Неравенство обработки данных и неравенство Фано 35
2.1.2 Отбор признаков на основе взаимной информации 36
2.1.3 Принцип максимума энтропии и логистическая регрессия 39

2.1. Элементарные приложения

2.1.1. Неравенство обработки данных и неравенство Фано

В данном подразделе мы рассматриваем исключительно дискретные случайные величины. Основание логарифма подразумевается равным 2.

Определение 2.1.1 (Марковская цепь)**.** Случайные величины ξ, η, ζ со значениями в $\mathcal{X}, \mathcal{Y}, \mathcal{Z}$ соответственно образуют марковскую цепь (обозначение: $\xi \to \eta \to \zeta$), если для всех $x \in \mathcal{X}, y \in \mathcal{Y}, z \in \mathcal{Z}$, таких что $\mathbb{P}(\eta = y, \zeta = z) > 0$,

$$\mathbb{P}(\zeta = z \mid \eta = y, \xi = x) = \mathbb{P}(\zeta = z \mid \eta = y).$$

Замечание. В терминах функций вероятности, есть несколько эквивалентных формулировок $p_{\xi\eta\zeta}(x, y, z) = p_\xi(x)p_{\eta|\xi}(y|x)p_{\zeta|\eta}(z|$ или, что то же самое, $p_{\zeta|\xi\eta}(z|x, y) = p_{\zeta|\eta}(z|y)$.

Замечание. если при условии η величины ξ и ζ независимы.

Лемма 2.1.2 (Условная независимость в марковской цепи)**.** *Если $\xi \to \eta \to \zeta$, то условная взаимная информация $\mathcal{I}(\xi; \zeta \mid \eta) = 0$.*

Доказательство. По определению условной взаимной информации:

$$\mathcal{I}(\xi; \zeta \mid \eta) = \sum_{x,y,z} p_{\xi\eta\zeta}(x, y, z) \log_m \frac{p_{\xi\zeta|\eta}(x, z|y)}{p_{\xi|\eta}(x|y)p_{\zeta|\eta}(z|y)}.$$

Из марковского свойства $p_{\xi\zeta|\eta}(x, z|y) = p_{\xi|\eta}(x|y)p_{\zeta|\eta}(z|y)$, поэтому логарифм равен нулю для всех слагаемых, и вся сумма обращается в ноль. □

Теорема 2.1.3 (Неравенство обработки данных (Data Processing Inequality))**.** *Пусть $\xi \to \eta \to \zeta$ образуют марковскую цепь. Тогда:*

$$\mathcal{I}(\xi; \eta) \geq \mathcal{I}(\xi; \zeta).$$

Иными словами, никакая обработка данных η не может увеличить количество информации о ξ.

Доказательство. Рассмотрим величину $\mathcal{I}(\xi; \eta; \zeta)$ — взаимную информацию трёх величин. С одной стороны:

$$\mathcal{I}(\xi; \eta; \zeta) = \mathcal{I}(\xi; \zeta) - \mathcal{I}(\xi; \zeta \mid \eta).$$

С другой стороны:

$$\mathcal{I}(\xi; \eta; \zeta) = \mathcal{I}(\xi; \eta) - \mathcal{I}(\xi; \eta \mid \zeta).$$

Из леммы 2.1.2 следует, что $\mathcal{I}(\xi; \zeta \mid \eta) = 0$. Подставляя это в первое равенство, получаем:

$$\mathcal{I}(\xi; \eta; \zeta) = \mathcal{I}(\xi; \zeta).$$

Из второго равенства имеем $\mathcal{I}(\xi; \eta; \zeta) = \mathcal{I}(\xi; \eta) - \mathcal{I}(\xi; \eta \mid \zeta) \leq \mathcal{I}(\xi; \eta)$, поскольку условная взаимная информация неотрицательна. Следовательно, $\mathcal{I}(\xi; \zeta) \leq \mathcal{I}(\xi; \eta)$, что и требовалось доказать. □

Теорема 2.1.4 (Неравенство Фано)**.** *Пусть $\eta \to \xi \to \hat{\eta}$ — марковская цепь, причём η и $\hat{\eta}$ принимают значения в одном и том же конечном множестве $\mathcal{K}$. Обозначим вероятность ошибки:*

$$P_{\text{error}} = \mathbb{P}(\eta \neq \hat{\eta}).$$

Тогда справедлива следующая оценка:

$$\mathrm{H}_m(\eta \mid \xi) \leq \mathrm{H}_m(P_{\text{error}}) + P_{\text{error}} \cdot \log_m(|\mathcal{K}| - 1),$$

где $\mathrm{H}_m(P_{\text{error}})$ — энтропия бернуллиевской случайной величины с вероятностью успеха P_{error}, то есть:

$$\mathrm{H}_m(P_{\text{error}}) = -P_{\text{error}} \log_m P_{\text{error}} - (1 - P_{\text{error}}) \log_m(1 - P_{\text{error}}).$$

Доказательство. Применим неравенство обработки данных (теорема 2.1.3) к цепи $\eta \to \xi \to \hat{\eta}$. Имеем:

$$\mathcal{I}(\eta; \xi) \geq \mathcal{I}(\eta; \hat{\eta}).$$

Заметим что $\mathcal{I}(\eta; \xi) = \mathrm{H}(\eta) - \mathrm{H}(\eta \mid \xi)$. $\mathcal{I}(\eta; \hat{\eta}) = \mathrm{H}(\eta) - \mathrm{H}(\eta \mid \hat{\eta})$. Откуда:

$$\mathrm{H}(\eta \mid \xi) \leq \mathrm{H}(\eta \mid \hat{\eta})$$

Теперь оценим $\mathrm{H}(\eta \mid \hat{\eta})$. Рассмотрим случайную величину $E = \mathbb{1}\{\{\eta \neq \hat{\eta}\}\}$ — индикатор ошибки. Применим правило цепочки для условной энтропии:

$$\mathrm{H}(\eta, E \mid \hat{\eta}) = \mathrm{H}(\eta \mid \hat{\eta}) + \underbrace{\mathrm{H}(E \mid \eta, \hat{\eta})}_{0}$$
$$\mathrm{H}(\eta, E \mid \hat{\eta}) = \mathrm{H}(E \mid \hat{\eta}) + \mathrm{H}(\eta \mid E, \hat{\eta})$$

Приравнивая правые части, получаем:

$$\mathrm{H}(\eta \mid \hat{\eta}) = \mathrm{H}(E \mid \hat{\eta}) + \mathrm{H}(\eta \mid E, \hat{\eta}).$$

Оценим каждое слагаемое. Имеем $\mathrm{H}(E \mid \hat{\eta}) \leq \mathrm{H}(E) = \mathrm{H}(P_{\text{error}})$, так как условная энтропия не превосходит безусловную. Распишем второе слагаемое:

$$\begin{aligned}
\mathrm{H}(\eta \mid E, \hat{\eta}) = \Bigg[\sum_{\hat{y} \in \mathcal{K}} \mathbb{P}(\eta = \hat{\eta}, \hat{\eta} = \hat{y}) \sum_{y \in \mathcal{K}} \overbrace{\mathbb{P}(\eta = y \mid \eta = \hat{\eta}, \hat{\eta} = \hat{y}) \log \mathbb{P}(\eta = y \mid \eta = \hat{\eta}, \hat{\eta} = \hat{y})}^{0} + \\
+ \sum_{\hat{y} \in \mathcal{K}} \mathbb{P}(\eta \neq \hat{\eta}, \hat{\eta} = \hat{y}) \sum_{y \in \mathcal{K}} \mathbb{P}(\eta = y \mid \eta \neq \hat{\eta}, \hat{\eta} = \hat{y}) \log \mathbb{P}(\eta = y \mid \eta \neq \hat{\eta}, \hat{\eta} = \hat{y}) \Bigg] = \\
= \sum_{\hat{y} \in \mathcal{K}} \mathbb{P}(\hat{\eta} = y, \eta \neq y) \sum_{\substack{y \in \mathcal{K} \\ y \neq \hat{y}}} \mathbb{P}(\eta = y \mid \eta \neq \hat{y}, \hat{\eta} = \hat{y}) \log \mathbb{P}(\eta = y \mid \eta \neq \hat{y}, \hat{\eta} = \hat{y}) \leq \\
\leq \sum_{\hat{y} \in \mathcal{K}} \mathbb{P}(\hat{\eta} = \hat{y}, \eta \neq \hat{y}) \cdot \log(|\mathcal{K}| - 1) = P_{\text{error}} \cdot \log(|\mathcal{K}| - 1)
\end{aligned}$$

Итак имеем:

$$\mathrm{H}(\eta \mid \xi) \leq \mathrm{H}(\eta \mid \hat{\eta}) = \mathrm{H}(E \mid \hat{\eta}) + \mathrm{H}(\eta \mid E, \hat{\eta}) \leq \mathrm{H}(E) + P_{\text{error}} \cdot \log(|\mathcal{K}| - 1)$$

Что в точности есть заключение теоремы. □

Следствие 2.1.5 (Принцип «Garbage In — Garbage Out»). *Пусть по наблюдаемым признакам ξ строится оценка некоторой ненаблюдаемой величины η: $\hat{\eta} = f(\xi)$; чем меньше $\mathcal{I}(\eta; \xi)$, тем хуже будет оценка. Иными словами* ***мусор на входе — мусор на выходе***

Следствие 2.1.6. *В задаче бинарной классификации, вероятность ошибки оценивается как*

$$\mathbb{P}(\text{predicted label } \neq \text{true label}) > \mathrm{H}(\text{true label } \mid \text{observed data})$$

2.1.2. Отбор признаков на основе взаимной информации

Итак, мы понимамем, что чтобы решать задачу предсказания, необходимо максимизировать взаимную информацию между целевой переменной η и имеющимися признаками $\xi = (\xi_1, \ldots, \xi_p)$. С точки зрения теории, это означает что нужно иметь как можно больше признаков: по правилу цепочки

$$\mathcal{I}(\xi; \eta) = \sum_{i=1}^{p} \mathcal{I}(\xi_i; \eta \mid \xi_{i-1}, \ldots, \xi_1)$$

взаимная информация будет увелиичиваться (не уменьшаться) с ростом p; На практике однако есть две проблемы.

- Производительность: огромное число признаков означает большее время обучения для большинства моделей; к тому же многие классические методы теряют численную устойчивость в больших размерностях.
- Точность: многие модели можно обмануть всевозможными странными зависимостями, присутствующими в данных.

Инженер по данным должен сделать сигнал максимально легко идентифицируемым для модели, чтобы она могла его изучить. На практике это означает, что **отбор признаков** может являться важным этапом предобработки. Отбор признаков помогает сконцентрироваться на релевантных переменных в наборе данных, а также может помочь устранить коллинеарные переменные. Он помогает уменьшить шум в наборе данных и помогает модели улавливать релевантные сигналы.

Методы фильтрации

В описанной ситуации мы обычно имеем матрицу данных высокой размерности $\mathbf{X} \in \mathbb{R}^{n \times p}$ и целевую переменную y (дискретную или непрерывную). Алгоритм отбора признаков выберет подмножество из $k \ll p$ столбцов, $\mathbf{X}_S \in \mathbb{R}^{n \times k}$, которые наиболее релевантны целевой переменной y.

В общем случае алгоритмы отбора признаков можно разделить на три класса:

1. **Методы-обёртки** используют обучающиеся алгоритмы на исходных данных $\mathbf{X}$ и выбирают релевантные признаки на основе (вневыборочной) производительности обучающегося алгоритма. Обучение линейной модели с различными комбинациями признаков и выбор признаков, дающих наилучшую вневыборочную производительность, было бы примером метода-обёртки.
2. **Методы фильтрации** не используют обучающийся алгоритм на исходных данных $\mathbf{X}$, а учитывают только статистические характеристики входных данных. Например, мы можем выбрать признаки, для которых корреляция между признаком и целевой переменной превышает пороговое значение корреляции.
3. **Встроенные методы** — это собирательная группа техник, которые выполняют отбор признаков как часть процесса построения модели. LASSO является примером встроенного метода.

Мы сосредоточимся на методах фильтрации, и в частности рассмотрим методы фильтрации, которые используют **взаимную информации**, для оценки того, какие признаки следует включить в уменьшенный набор данных $\mathbf{X}_S$. Результирующий критерий приводит к NP-трудной задаче оптимизации, и мы обсудим несколько способов, которыми можно попытаться найти оптимальные решения этой задачи.

Совместная взаимная информация как критерий для отбора признаков

Предоположим следующее: в нашем распоряжении есть достаточно большой набор пар вида «целевая перменная — вектор признаков»:

$$\mathcal{D} = \left\{ (y^{(i)}; \mathbf{x}^{(i)}) \right\}_{i=1}^{n},$$

где $y^{(i)} \in \mathbb{R}, \mathbf{x}^{(i)} \in \mathbb{R}^p$; Мы будем предполагать что пара $(y, \mathbf{x})$ это независимая реализация некоторой случайной величины (η, ξ), η — со значениями в $\mathbb{R}$, ξ со значениями в $\mathbb{R}^p$; Такая постановка позволяет говорить о взаимной информации $\mathcal{I}(\eta; \xi)$ между признаками ξ и целевой переменной η;

Когда дело доходит до отбора признаков, мы хотим максимизировать взаимную информацию между подмножеством выбранных признаков ξ_S и целевой переменной η:

$$\tilde{S} = \operatorname*{argmax}_S \mathcal{I}(\xi_S; \eta), \quad \text{при условии } |S| = K,$$

где K — количество признаков, которые мы хотим выбрать. Эта величина называется **совместной взаимной информацией**, и её максимизация является NP-трудной задачей оптимизации, потому что множество возможных комбинаций признаков растёт экспоненциально.

С точки зрения данных, мы можем записать взаимную информацию следующим образом:

$$\mathcal{I} = D_{\mathrm{KL}}(p_{\xi_S,\eta}(x_S, y) \parallel p_{\xi_S}(x_S) \cdot p_\eta(y)) = \mathbb{E}_{X_S \sim \xi_S, Y \sim \eta} \left[\log \left(\frac{p_{\xi_S,\eta}(X_S, Y)}{p_{\xi_S}(X_S) \cdot p_\eta(Y)} \right) \right] \approx \frac{1}{n} \sum_{i=1}^{n} \log \left(\frac{p_{\xi_S,\eta}(\mathbf{x}_S^{(i)}, y^{(i)})}{p_{\xi_S}(\mathbf{x}_S^{(i)}) \cdot p_\eta(y^{(i)})} \right)$$

В случае когда все данные дискретны, мы можем оценивать $p_{\xi_S,\eta}(X_S, Y)$ с помощью подсчета вхождений впар (X_S, Y) в набор $\mathcal{D}$; В непрерывном случае все несколько усложняется, однако и там есть свои методы.

Жадное решение задачи отбора признаков

Самый простой подход к решению этой оптимизационной задачи — жадный пошаговый алгоритм прямого отбора. Здесь признаки выбираются последовательно, по одному за раз. Пусть $S^{t-1} = \{x_{f_1}, \ldots, x_{f_{t-1}}\}$ — множество выбранных признаков на шаге $t-1$. Жадный метод выбирает следующий признак f_t такой, что

$$f_t = \operatorname*{argmax}_{r \notin S^{t-1}} \mathcal{I}(\xi_{S^{t-1} \cup r}; \eta).$$

Из правила цепочки мы можем записать:

$$\mathcal{I}(\xi_{S^{t-1} \cup r}; \eta) = \mathcal{I}(\xi_r; \eta \mid \xi_{S^{t-1}}) + \underbrace{\sum_{k=1}^{t-1} \mathcal{I}(\xi_k; \eta \mid \xi_{k-1}, \ldots, \xi_1)}_{\text{const}}$$

Таким образом, жадный отбор признаков выбирает признаки, которые на каждом шаге дают наибольшее увеличение совместной взаимной информации. Однако даже такой подход, на каждом шаге требует огромное количество рассчетов. Теперь используем определение информации взаимодействия:

$$\mathcal{I}(\xi_r;\eta;\xi_{S^{t-1}}) = \mathcal{I}(\xi_r;\eta) - \mathcal{I}(\xi_r;\eta \mid \xi_{S^{t-1}}) = \mathcal{I}(\xi_r;\xi_{S^{t-1}}) - \mathcal{I}(\xi_r;\xi_{S^{t-1}} \mid \eta)$$

Тогда:

$$f_t = \operatorname*{argmax}_{r\notin S^{t-1}} \underbrace{\mathcal{I}(\xi_r;\eta)}_{\text{релевантность}} - \underbrace{\left[\mathcal{I}(\xi_r;\xi_{S^{t-1}}) - \mathcal{I}(\xi_r;\xi_{S^{t-1}} \mid \eta)\right]}_{\text{избыточность}}.$$

Это даёт нам понимание того, что по существу означает оптимизация данного критерия. Оптимизация этого критерия приводит к компромиссу между *релевантностью* нового признака x_i по отношению к цели y и *избыточностью* этой информации по сравнению с информацией, содержащейся в уже выбранных переменных $X_{S^{t-1}}$.

Аппроксимация меньшей размерности

Даже с приведённым выше упрощением совместной взаимной информации, величины, включающие S^{t-1}, всё ещё являются $(t-1)$-мерными интегралами. Чтобы сделать задачу более разрешимой, многие подходы в литературе предлагают одну или обе из следующих аппроксимаций низкого порядка:

$$I(x_i;x_{S^{t-1}}) \approx \alpha \sum_{k=1}^{t-1} I(x_{f_k};x_i), \tag{2.1}$$

$$I(x_i;x_{S^{t-1}}|y) \approx \beta \sum_{k=1}^{t-1} I(x_{f_k};x_i|y). \tag{2.2}$$

Следовательно, задача оптимизации теперь упрощается до

$$f_t = \arg\max_{i\notin S^{t-1}} \underbrace{I(x_i;y)}_{\text{релевантность}} - \underbrace{\left[\alpha \sum_{k=1}^{t-1} I(x_{f_k};x_i) - \beta \sum_{k=1}^{t-1} I(x_{f_k};x_i|y)\right]}_{\text{избыточность}}$$

где α и β должны быть заданы.

Семейство алгоритмов отбора признаков

Эти параметры фактически определяют семейство критериев, основанных на взаимной информации, и мы можем получить некоторые известные примеры для конкретных значений α и β:

- Совместная взаимная информация (JMI): $\alpha = \frac{1}{t-1}$ и $\beta = \frac{1}{t-1}$.
- Максимальная релевантность — минимальная избыточность (MRMR): $\alpha = \frac{1}{t-1}$ и $\beta = 0$.
- Максимизация взаимной информации (MIM): $\alpha = 0$ и $\beta = 0$.

Различные значения α и β имеют значение для того, что вы предполагаете о вероятностной структуре ваших данных. Они соответствуют одному (или обоим) из следующих предположений:

Предположение 2: Все признаки попарно условно независимы при условии класса, т.е.

$$p(x_i x_j|y) = p(x_i|y)p(x_j|y).$$

Это означает, что $\sum I(X_j;X_k|y)$ будет равно нулю.

Предположение 3: Все признаки попарно независимы, т.е.

$$p(x_i x_j) = p(x_i)p(x_j).$$

Это означает, что $\sum I(X_j;X_k)$ будет равно нулю.

Теперь мы можем видеть, что α и β контролируют степень уверенности в одном из этих предположений:

- Значение α, близкое к нулю, указывает на более сильную уверенность в Предположении 3.
- Значение β, близкое к нулю, указывает на более сильную уверенность в Предположении 2.
- Все критерии отбора переменных принимают Предположение 1.

2.1.3. Принцип максимума энтропии и логистическая регрессия

Итак, допустим мы установили, что чем больше в данных информации о целевой переменной, тем лучше нижняя граница на вероятность ошибки. Неравенство Фано, однако, ничего не говорит о том, как же нам получить «хорошую» оценку, и вообще говоря не должно. Данные — это одна история, предсказательная модель — другая. Дизайн моделей, это отдельный большой и сложный раздел, который мы можем затронуть только поверхностно, рассмотрев один из принципов, которые можно использовать: принцип максимума энтропии.

Принцип максимума энтропии. Для описания набора данных $\mathcal{D}$, которые

1. имеют вероятностную природу (т.е. $\mathcal{D}$ можно мыслить как реализацию некоторого случайного объекта, например, в самом простом случае $\mathcal{D} = \{(y, \mathbf{x}_i)\}_{i=1}^n, \mathbf{x}_i \in \mathbb{R}^d$)
2. распределение данных имеют некоторые ограничения (например, зафиксировано математическое ожидание Y;